Business Intelligence

Tarea 4: Introducción a Series de Tiempo

Hugo Roberto Tobías Mejía
Facultad de Ingeniería, Universidad del Istmo de Guatemala

25 de octubre de 2026

Resumen

Se analiza la serie de venta neta diaria de una tienda en línea del Reino Unido entre diciembre de 2010 y diciembre de 2011. El trabajo tiene dos mitades. En la primera se construye el vocabulario con procesos simulados donde la respuesta se conoce de antemano: se verifica que la prueba de autocorrelación de rezago 1 rechaza al 5 % bajo ruido blanco, que el estimado OLS de ϕ tiene sesgo hacia abajo cerca de la raíz unitaria, y que un proceso *sin memoria* cuya media cambia con el tiempo reprueba la prueba de ruido blanco igual que uno con memoria. En la segunda se trabaja con datos reales y sucios: se documenta una limpieza de seis reglas que elimina 7,930 de 541,909 filas, se reconstruye el calendario (la tienda no abre los sábados: la estacionalidad es de período $s = 6$, no 7), se ajustan dos modelos SARIMA y se comparan siete modelos de pronóstico con origen móvil semanal. El modelo SARIMA$(0,1,1)(0,1,1)_6$ gana en prueba con un MAE de £12,817, y es el único cuyos residuos pasan la prueba de Ljung–Box. Se muestra además que un predictor construido con una media móvil *centrada* mejora el error estimado en un 10 % sin que la validación cruzada ni el origen móvil lo detecten. Finalmente, un análisis RFM muestra que el 21.4 % de los clientes genera el 53.5 % de la venta del período de prueba, y que el 15.7 % de esa venta viene de clientes nuevos, a los que ningún modelo cliente por cliente puede ver.

Repositorio y reproducibilidad. Todo el código está en el repositorio de GitHub que acompaña a esta entrega. La tarea se reproduce completa desde el archivo original `data/Online Retail.xlsx` con `python src/run_all.py` (unos 90 segundos). Las semillas están documentadas: 2,026–2,031 en la Parte 0 y 2,026 en la Parte 6.

Nota sobre `statsmodels`. El entorno de cómputo donde se ejecutó esta tarea no tenía acceso a PyPI, así que `statsmodels` no se pudo instalar. En lugar de omitir la Parte 4, el modelo SARIMA se implementó desde cero en `src/utils_ts.py`: representación de espacio de estados de Harvey para un ARMA(p, q), filtro de Kalman para la verosimilitud gaussiana exacta, σ^2 concentrada fuera de la optimización y L-BFGS-B para maximizar. La interfaz imita la de `SARIMAX` (`fit(maxiter=...)`, `res.resid`, `res.mle_retvals['converged']`, `res.forecast(h)`). La implementación se verifica en `src/test_sarima.py` con 24 pruebas que recuperan los parámetros de procesos simulados con valores conocidos; todas pasan. La prueba de Ljung–Box y la función r_k también están implementadas a mano, como pide el enunciado.

Índice

Parte 0: Procesos simulados **4**

0.1 Las derivaciones a mano . . . 4
0.2–0.3 Simulación del AR(1) . . . 5
0.4 Las dos razones para reprobar . . . 7
0.5 La prueba que sí ve . . . 8

Parte 1: Limpieza **8**
1.1 Qué hay en el archivo . . . 8
1.2 Los seis casos, uno por uno . . . 9
1.3 La bitácora de limpieza . . . 11
1.4 Las seis líneas más grandes . . . 11
1.5 La función `limpiar` . . . 12

Parte 2: El calendario **13**
2.1 Cuántos días hay y cuántos se usaron . . . 13
2.2 Los días sin transacciones . . . 13
2.3 *¿Un día sin transacciones es un cero o un dato faltante?* . . . 14
2.4 *¿Está completo el último día?* . . . 14

Parte 3: Tendencia, estacionalidad y autocorrelación **15**
3.1 Tendencia . . . 15
3.2 Estacionalidad . . . 16
3.3 Autocorrelación . . . 18

Parte 4: Del AR(1) al SARIMA **19**
4.1 Quitar el día de la semana . . . 19
4.2 Un AR(1) para la memoria que queda . . . 21
4.3 SARIMA . . . 22
4.4 Diagnóstico . . . 23
4.5 *¿Hacia dónde van los pronósticos?* . . . 24

Parte 5: Pronóstico y fuga **24**
5.1 Los seis modelos . . . 24
5.2–5.3 Los tres estimados del error . . . 25
5.4 La trampa . . . 27
5.5 Por qué todo lo estimado adentro se queda corto . . . 28

Parte 6: Detrás de la serie hay clientes **29**
6.1 Construcción de R, F y M . . . 29
6.2 Puntajes por quintiles . . . 30

6.3 *¿Qué dimensión separa mejor?* 31
6.4 Los campeones 32
6.5 Los clientes nuevos y el límite del enfoque 33

Conclusiones **34**

Parte 0: Procesos simulados

0.1 Las derivaciones a mano

Sea el AR(1) estacionario $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $|\phi| < 1$ y $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, donde ε_t es independiente de todo el pasado del proceso.

La media. La estacionariedad débil pide que $E[Y_t]$ no dependa de t. Llámese μ a ese valor común. Tomando esperanza en ambos lados,

$$\mu = E[Y_t] = c + \phi\, E[Y_{t-1}] + E[\varepsilon_t] = c + \phi\mu + 0,$$

de donde $\mu(1-\phi) = c$ y, como $|\phi| < 1$ garantiza $1 - \phi \neq 0$,

$$\boxed{E[Y_t] = \frac{c}{1-\phi}.}$$

La varianza. Ahora se usa que $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1})$, de nuevo por estacionariedad. Como ε_t es independiente de Y_{t-1}, la varianza de la suma es la suma de las varianzas:

$$\mathrm{Var}(Y_t) = \phi^2\, \mathrm{Var}(Y_{t-1}) + \sigma^2 = \phi^2\, \mathrm{Var}(Y_t) + \sigma^2.$$

Despejando,

$$\boxed{\mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}.}$$

Aquí se ve por qué hace falta $|\phi| < 1$: si $|\phi| \geq 1$ el denominador se anula o se vuelve negativo y no existe una varianza finita constante.

La autocorrelación. Sea $\tilde{Y}_t = Y_t - \mu$, de modo que $\tilde{Y}_t = \phi \tilde{Y}_{t-1} + \varepsilon_t$. Para $k \geq 1$,

$$\gamma_k = \mathrm{Cov}(Y_t, Y_{t-k}) = E[\tilde{Y}_t \tilde{Y}_{t-k}] = E[(\phi \tilde{Y}_{t-1} + \varepsilon_t)\tilde{Y}_{t-k}] = \phi\, \gamma_{k-1} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-k}]}_{=0},$$

donde el último término es cero porque ε_t es independiente del pasado y tiene media cero. Entonces $\gamma_k = \phi \gamma_{k-1}$ para todo $k \geq 1$, y aplicando la recursión k veces, $\gamma_k = \phi^k \gamma_0$. Dividiendo entre γ_0,

$$\boxed{\rho_k = \phi^k.}$$

La autocorrelación de un AR(1) decae *geométricamente*: la memoria no se corta de golpe, se desvanece. Este resultado se usa en la Parte 4.1 para distinguir la forma de la ACF de un AR(1) de la de una serie con tendencia.

La caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$ se tiene $Y_t = Y_{t-1} + \varepsilon_t$, y desenrollando la recursión,

$$Y_t = \sum_{j=1}^{t} \varepsilon_j.$$

Como los ε_j son independientes,

$$\boxed{\mathrm{Var}(Y_t) = \sum_{j=1}^{t} \mathrm{Var}(\varepsilon_j) = t\sigma^2.}$$

Por qué eso la hace no estacionaria. La estacionariedad débil exige que la varianza sea la misma en todo momento. Aquí crece sin límite con t: la serie en el día 300 es mucho más dispersa que en el día 10. Dicho de otra forma, un choque ε_j entra en la suma y se queda ahí para siempre; la caminata aleatoria nunca olvida. Por eso el pronóstico de una caminata aleatoria es simplemente el último valor observado, y por eso diferenciar (pasar de niveles a cambios) la convierte en ruido blanco. Esa es la idea que motiva la d de los modelos ARIMA de la Parte 4.

0.2–0.3 Simulación del AR(1)

Se simularon $n = 300$ pasos con $c = 0$ y $\sigma = 1$, descartando los primeros 200 para que el valor inicial no importe, y 5,000 réplicas por escenario con una semilla distinta en cada uno.

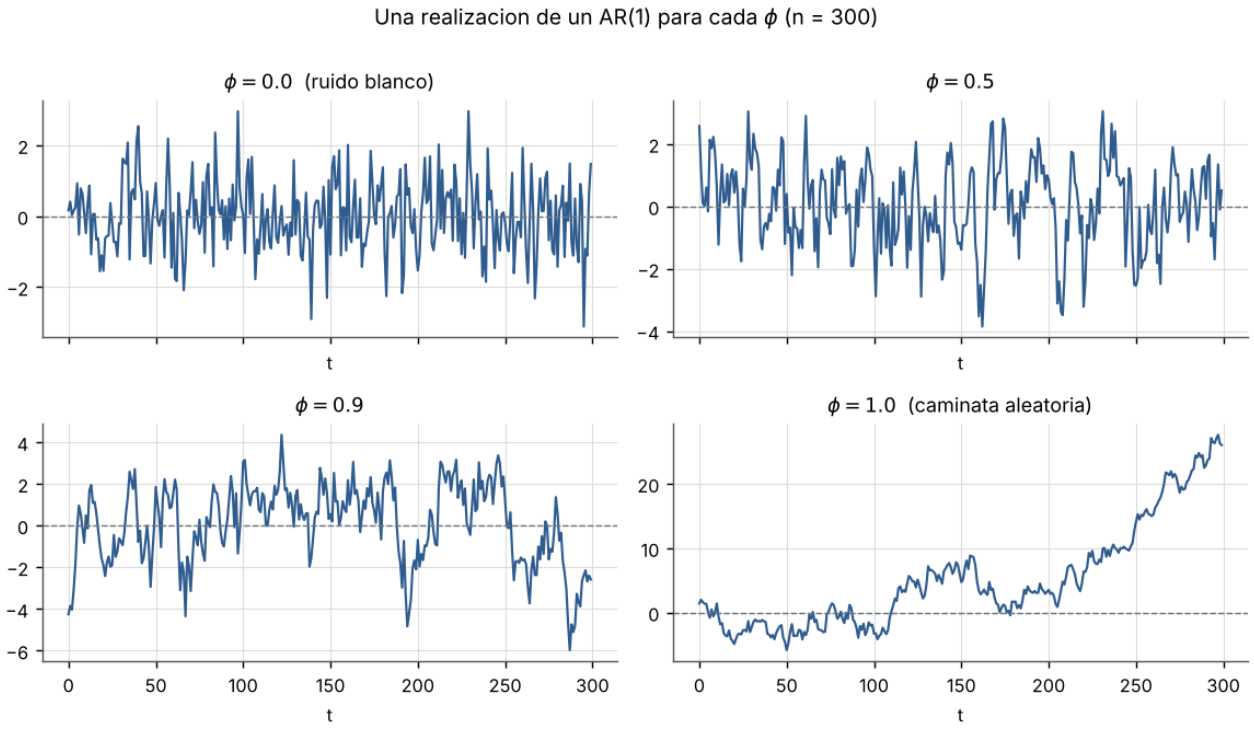


Figura 1: Una realización de un AR(1) para cada ϕ. **Qué muestra:** con $\phi = 0$ la serie es ruido blanco y cruza el cero todo el tiempo; con $\phi = 0.5$ aparecen rachas cortas; con $\phi = 0.9$ las rachas son largas y la serie tarda en volver a su media; con $\phi = 1$ ya no hay media a la cual volver y la serie se va caminando. **Por qué importa:** es la misma serie de ecuaciones con un solo parámetro distinto, y produce cuatro comportamientos cualitativamente diferentes.

Sobre el descarte con $\phi = 1$. El enunciado advierte que con $\phi = 1$ descartar los primeros 200 pasos no logra que el valor inicial deje de importar, y es cierto: la caminata aleatoria no olvida, así que al día 200 la serie arranca desde un nivel aleatorio en lugar de desde cero. *Pero eso no afecta a*

r_k, porque r_k se calcula sobre las desviaciones respecto a la media muestral $\bar{y}$. Sumar una constante a toda la serie no cambia ni el numerador ni el denominador de

$$r_k = \frac{\sum_{t=k+1}^{n}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{n}(y_t - \bar{y})^2}.$$

El descarte traslada la serie; r_k es invariante a traslaciones.

Tabla 1: 0.2 AR(1) simulado: $n = 300$, 5 000 réplicas por escenario. Cada celda trae el promedio sobre las réplicas y, en pequeño, su error estándar. La banda de la prueba de rezago 1 es $\pm 1.96/\sqrt{300} = 0.1132$.

ϕ	**prom.** r_1	**prom.** r_5	ϕ^5 **teórico**	**tasa rechazo** $\lvert r_1 \rvert$	**prom.** $\hat{\phi}_{\mathbf{OLS}}$	**semilla**
0.00	-0.0039 $\pm$0.0008	-0.0028 $\pm$0.0008	0.0000	0.0500 $\pm$0.0031	-0.0039 $\pm$0.0008	2026
0.50	0.4892 $\pm$0.0007	0.0199 $\pm$0.0010	0.0312	1.0000 $\pm$0.0000	0.4909 $\pm$0.0007	2027
0.90	0.8839 $\pm$0.0004	0.5339 $\pm$0.0014	0.5905	1.0000 $\pm$0.0000	0.8871 $\pm$0.0004	2028
1.00	0.9758 $\pm$0.0002	0.8835 $\pm$0.0009	1.0000	1.0000 $\pm$0.0000	0.9824 $\pm$0.0002	2029

Qué leer: con $\phi = 0$ la tasa de rechazo es exactamente el 5 % nominal. Con $\phi = 1$, $r_5 = 0.88$ en vez del $\phi^5 = 1$ teórico, porque la fórmula supone estacionariedad. Y $\hat{\phi}_{\mathrm{OLS}}$ está sesgado hacia abajo, cada vez más conforme $\phi \to 1$.

0.3 Con $\phi = 0$, *¿la tasa de rechazo es la que esperaban?* Sí, y es tranquilizador. Se obtuvo 0.050,0 contra el 0.05 teórico (error estándar 0.003,1). Esto es exactamente lo que *debe* pasar: bajo ruido blanco, $r_1 \approx \mathcal{N}(0, 1/n)$, así que la probabilidad de que $|r_1|$ se salga de la banda $\pm 1.96/\sqrt{n}$ es del 5 % por construcción. Una prueba al 5 % rechaza el 5 % de las veces cuando la hipótesis nula es verdadera; eso no es un defecto, es la definición del nivel de significancia. Esta cifra es la calibración de la prueba y sirve de referencia para leer todo lo demás.

0.3 Para la caminata aleatoria, *¿qué pasa con r_5 comparado con la teoría $\phi^5 = 1$?* La teoría dice $\rho_5 = 1$, pero el promedio muestral es 0.883,5, muy por debajo. La razón es que la fórmula $\rho_k = \phi^k$ se derivó *suponiendo estacionariedad*, y la caminata aleatoria no lo es: ni siquiera tiene una media poblacional a la cual restar. Al calcular r_5 se resta la media *muestral* del tramo observado, que es un número distinto en cada réplica y que absorbe parte del movimiento de la serie. El resultado es un r_k sistemáticamente menor que 1 y que además decae conforme crece k, cuando la teoría diría que se queda clavado en 1.

0.3 *¿Es consistente el estimado OLS de ϕ con el verdadero, o ven un sesgo?* Hay sesgo, y es hacia abajo. El patrón es claro en la tabla: con $\phi = 0$ el estimado promedio es $-0.003,9$ (prácticamente insesgado), con $\phi = 0.5$ es 0.490,9, con $\phi = 0.9$ es 0.887,1 y con $\phi = 1$ es 0.982,4. El sesgo crece conforme ϕ se acerca a 1: de 0.004 a 0.009, 0.013 y 0.018. Los errores estándar de esos promedios son del orden de 0.000,8, así que el sesgo es decenas de veces mayor que el ruido de simulación: no es casualidad.

La razón es que en una regresión de y_t contra y_{t-1} el regresor *no* es fijo: está correlacionado con los errores pasados. Eso rompe el supuesto que hace insesgado al OLS. El efecto es pequeño cuando la memoria es corta, pero se agrava cerca de la raíz unitaria; es el mismo fenómeno que hace que las pruebas de raíz unitaria tipo Dickey–Fuller necesiten tablas propias en vez de la distribución normal. En la práctica significa que, al estimar un AR en datos muy persistentes, uno tiende a concluir que la serie es *menos* persistente de lo que realmente es.

0.4 Las dos razones para reprobar

Ahora se simulan procesos **sin memoria**, $Y_t = m_t + \varepsilon_t$ con ε_t iid $\mathcal{N}(0,1)$, pero cuya media cambia con el tiempo.

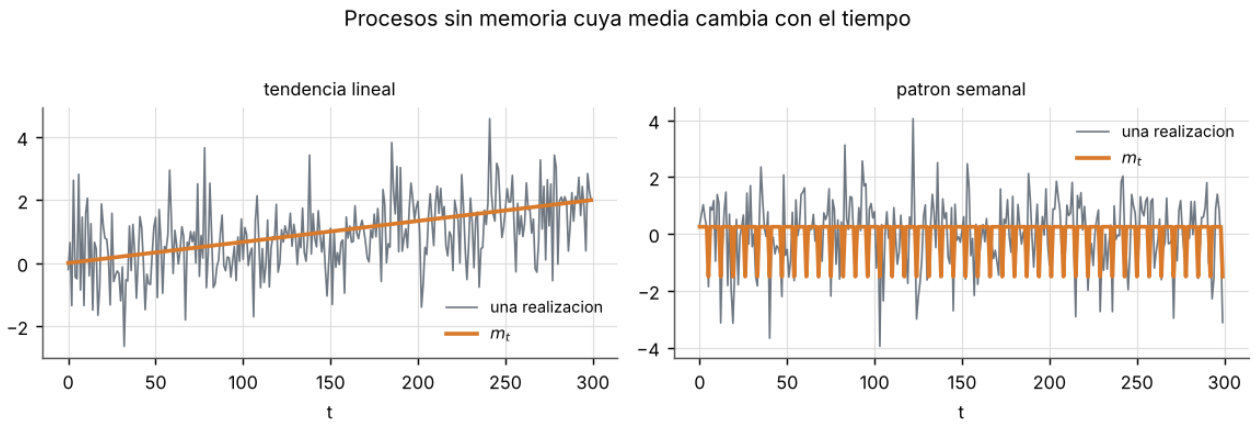


Figura 2: Los dos procesos de 0.4. **Qué muestra:** en gris una realización, en naranja la media m_t que la genera. Entre un punto y el siguiente no hay ninguna dependencia: cada ε_t es independiente de todos los demás. **Por qué importa:** estas dos series no tienen memoria y, aun así, reprueban la prueba de ruido blanco.

Tabla 2: 0.4 Procesos *sin memoria* cuya media cambia con el tiempo. 5 000 réplicas de $n = 300$ por escenario.

escenario	prom. r_1	prom. r_7	tasa rechazo $\lvert r_1 \rvert$	semilla
ruido blanco (phi=0)	-0.0039 $\pm$0.0008	-0.0017 $\pm$0.0008	0.0500 $\pm$0.0031	2026
tendencia lineal =2t/300	0.2445 $\pm$0.0008	0.2296 $\pm$0.0008	0.9846 $\pm$0.0017	2030
patron semanal =-1.5 si t mod 7 = 6	-0.0484 $\pm$0.0008	0.2646 $\pm$0.0008	0.1146 $\pm$0.0045	2031

Qué leer: la tendencia reprueba la prueba de rezago 1 el 98.5 % de las veces sin tener ninguna memoria. El patrón semanal la *pasa* (11.5 %) aunque su $r_7 = 0.26$ delata una estructura enorme: la prueba mira donde no hay nada.

¿Cuál reprueba la prueba de retardo 1 aunque no tenga memoria? La de **tendencia lineal**. Rechaza en el 98.46 % de las réplicas, con un r_1 promedio de 0.244,5. El mecanismo es el que anticipa el enunciado: $\bar{y}$ no es la media de nadie. Los días de la parte alta de la tendencia quedan todos arriba de $\bar{y}$ y sus vecinos también, así que el producto $(y_t - \bar{y})(y_{t-1} - \bar{y})$ es positivo una y otra vez, y r_1 sale grande. La prueba supone estacionariedad y reprueba porque *ese* supuesto es falso, no porque exista dependencia.

¿Cuál la pasa aunque tenga estructura? La del **patrón semanal**. Rechaza en apenas el 11.46 % de las réplicas, con $r_1 = -0.048,4$: la prueba de rezago 1 casi no la ve. Y sin embargo la estructura está ahí, enorme: $r_7 = 0.264,6$. La media baja a -1.5 cada siete pasos y sube a 0.25 el resto, de modo que días separados por exactamente siete pasos se parecen mucho, pero días consecutivos no. La prueba de rezago 1 mira justo donde no hay nada.

Conéctenlo con RANDU en la Tarea 2: ¿qué tienen en común? Que una prueba solo ve lo que mira, y que pasar una prueba no es evidencia de que no haya estructura. RANDU produce números que

lucen uniformes e independientes en una y en dos dimensiones, y solo al mirarlos en *tres* dimensiones se descubre que caen en quince planos. El patrón semanal es el mismo cuento con otro disfraz: es limpio en el rezago 1 y culpable en el rezago 7. En ambos casos el generador (o el proceso) *pasa* la prueba equivocada. La lección práctica es que una sola prueba de diagnóstico, por bien construida que esté, solo cubre la dirección en la que apunta.

0.5 La prueba que sí ve

Tabla 3: 0.5 Tasa de rechazo al 5 % de Ljung–Box con $m = 10$, frente a la prueba de un solo rezago.

escenario	Ljung–Box $m = 10$	prueba de rezago 1
ruido blanco (phi=0)	0.0612 ±0.0034	0.0500 ±0.0031
tendencia lineal	1.0000 ±0.0000	0.9846 ±0.0017
patron semanal	0.9554 ±0.0029	0.1146 ±0.0045

Qué leer: el caso semanal es el que cambia. Ljung–Box lo rechaza el 95.5 % de las veces contra el 11.5 % de la prueba de rezago 1, porque $Q(10)$ incluye el rezago 7 en la suma.

¿Qué cambia respecto a la prueba de retardo 1? ¿Por qué? Cambia el caso semanal, y de forma dramática: la prueba de rezago 1 lo deja pasar el 88.5 % de las veces, mientras que Ljung–Box con $m = 10$ lo rechaza el 95.54 % de las veces. La razón es puramente de cobertura: $Q(10)$ suma $r_1^2, \ldots, r_{10}^2$ en un solo estadístico, así que el rezago 7 entra a la suma y el $r_7 = 0.264{,}6$ se hace notar. La prueba de rezago 1 ni siquiera lo calcula.

Para el ruido blanco, Ljung–Box rechaza en el 6.12 % de las réplicas, razonablemente cerca del 5 % nominal (con $n = 300$ y $m = 10$ la aproximación χ^2 es buena, aunque no exacta). Y para la tendencia rechaza siempre, igual que la prueba de rezago 1.

Lo que esto enseña, y que se aplicará directamente en las Partes 3 y 4, es que conviene juntar rezagos en vez de mirarlos de uno en uno. Con 20 rezagos mirados individualmente al 5 % se espera que uno se salga por pura suerte; ese es justamente el problema de comparaciones múltiples que las pruebas portmanteau resuelven. Sobre cuántos rezagos usar, los dos libros discrepan: FPP2 recomienda $m = 10$ sin estacionalidad y $m = 2s$ con ella (sin pasar de $n/5$), mientras que Tsay cita simulaciones que favorecen $m \approx \log(n)$. En esta tarea se reportan ambos extremos, $Q(6)$ y $Q(12)$, y en los datos reales llevan a la misma conclusión en todos los casos salvo uno, que se señala en su momento.

Parte 1: Limpieza

1.1 Qué hay en el archivo

Una cuarta parte de las filas, el 24.93 %, no tiene `CustomerID`. Esa fracción es demasiado grande para ignorarla y la decisión sobre qué hacer con ella se discute en el inciso 1.2(f).

Por qué leer `InvoiceNo`, `StockCode` y `CustomerID` como texto. El enunciado da el consejo y pide averiguar por qué. Son tres razones distintas:

- `InvoiceNo` trae prefijos de letra (`C` de cancelación, `A` de ajuste). No es un número, es una etiqueta. Leído como número, pandas se rinde y lo deja como texto mezclado, o peor, descarta los prefijos.

Tabla 4: 1.1 El archivo antes de limpiar.

concepto	valor
filas	541909
facturas distintas	25900
productos distintos (StockCode)	4070
clientes distintos (CustomerID)	4372
paises	38
filas sin CustomerID	135080
fraccion de filas sin CustomerID	0.2493
primera fecha	2010-12-01 08:26:00
ultima fecha	2011-12-09 12:50:00
venta bruta sin limpiar (GBP)	9747747.93

Qué leer: una cuarta parte de las filas no tiene cliente identificado; qué hacer con ellas es la decisión más delicada de la limpieza.

- `StockCode` mezcla dígitos con letras: `22423` pero también `22423H`, `POST`, `DCGS0003`. El sufijo de letra distingue variantes de un mismo producto y perderlo fusionaría productos distintos.
- `CustomerID` es un identificador, no una cantidad: no tiene sentido promediarlo. Y como tiene faltantes, pandas lo convierte a `float`, con lo que el cliente 17,850 aparece como `17850.0`. Al cruzarlo después contra una tabla donde está como texto, no empata nada y el error es silencioso.

1.2 Los seis casos, uno por uno

Tabla 5: 1.2 Los seis casos del enunciado, con su tamaño y la decisión tomada. La justificación de cada uno está en el texto.

caso	filas	monto (£)	decisión
(a) filas duplicadas exactas	5 268	21 741	**SE VAN**
(b) facturas con prefijo 'A'	3	-11 062	**SE VAN**
(b) facturas con prefijo 'C'	9 288	-896 812	**SE QUEDAN**
(c) StockCode que no es venta (AMAZONFEE, BANK CHARGES, CRUK, B, S)	153	-250 741	**SE VAN**
(c) StockCode especial que SI es venta (POST, DOT, C2, D, M, PADS, gift	2 763	205 094	**SE QUEDAN**
(d) precio unitario igual a cero	2 515	0	**SE VAN**
(d) precio unitario negativo	2	-22 124	**SE VAN**
(e) cantidad negativa en factura que no es cancelacion	1 336	0	**SE VAN**
(f) filas sin CustomerID	135 080	1 447 682	**SE QUEDAN (para la serie)**

Qué leer: las dos decisiones de *conservar* son tan importantes como las de eliminar. Las cancelaciones deben restar el día en que ocurren, y las filas sin cliente son 1.45 millones de libras de venta real.

La decisión de fondo es siempre la misma pregunta: *¿esta línea es dinero que un cliente pagó (o dejó de pagar) por algo que la tienda le vendió?* Si la respuesta es sí, la línea se queda aunque el monto sea negativo. Si es un ajuste contable, un cargo de un tercero o un movimiento de inventario, se va.

(a) Duplicados exactos. 5,268 filas idénticas carácter por carácter: misma factura, mismo producto, misma cantidad, mismo minuto. Dos clientes no compran lo mismo en el mismo segundo de

la misma factura; es un error de captura o de exportación. **Se van**, conservando la primera aparición. Si se dejaran, su monto se contaría dos veces.

(b) Facturas que no empiezan con dígito. Hay dos prefijos. Las 9,288 filas con `C` son cancelaciones y **se quedan**, porque el enunciado pide expresamente que resten el día en que ocurren. Las tres filas con `A` dicen `Adjust bad debt` y son ajustes contables por deuda incobrable, con montos de ±£11,062: no son una venta ni la cancelación de una venta, sino un movimiento del libro mayor. **Se van**.

(c) `StockCode` que no son productos. Aquí el enunciado advierte que no todos son iguales, y en efecto hay tres grupos.

- **Sí son productos, aunque el código sea raro**: `DCGS*` (bolsas de fiesta, collares de perro, una lámpara), `PADS`, y los vales de regalo `gift_0001_*`. **Se quedan**.
- **No son productos pero sí son venta**: `POST`, `DOT` y `C2` son cargos de envío que el cliente paga, y suman £279,462 de ingreso; `D` es un descuento, que reduce legítimamente la venta neta. **Se quedan**.
- **No son venta**: `AMAZONFEE` y `CRUK` son comisiones que cobran terceros, `BANK CHARGES` son cargos del banco, `B` es otro ajuste de deuda incobrable y `S` son muestras que salen de inventario sin venderse. Son gastos o movimientos de bodega, no dinero que entró por una venta. **Se van** (149 filas).

El caso de `M` (Manual) merece párrafo propio, porque es donde está la trampa. Es tentador borrarlo por ambiguo: son 571 líneas capturadas a mano cuya descripción es simplemente `Manual`. Pero borrarlo sería un error, y el inciso 1.4 lo demuestra: la factura `C556445` es una línea `Manual` de −£38,970 que cancela la cesta de picnic de la factura `556444` del mismo día. Si se elimina `M`, la venta de £38,970 se queda huérfana y aparece un pico falso en la serie. **Se queda**.

(d) Precios cero o negativos. Hay 2,515 filas con precio exactamente cero. No aportan nada a la venta neta y 1,454 de ellas ni siquiera tienen descripción; el resto dice `check`, `damages`, `?`. Son movimientos de bodega. **Se van**. Los dos precios negativos son las facturas `A` de deuda incobrable, que la regla (b) ya se había llevado.

(e) Cantidades negativas en facturas que no son cancelación. Son 1,336 filas, y la columna `Description` las delata: `damages`, `check`, `?`, `thrown away`, `Unsaleable, destroyed.`, `wet pallet`, `smashed`. No son devoluciones de clientes sino ajustes de inventario que alguien anotó a mano. Un detalle importante: **las 1,336 tienen precio cero**, así que su monto es exactamente £0.00 y quitarlas no mueve ni una libra de la serie. Sí mueve los conteos, y por eso importa el orden de las reglas. **Se van**.

(f) Filas sin `CustomerID`. Esta es la única regla cuya respuesta depende de para qué se vaya a usar el dato, y el enunciado lo advierte.

Para la **serie de ventas**: una transacción sin cliente identificado sigue siendo dinero que entró a la caja. Son el 24.93 % de las filas y alrededor de £1.45 millones. Borrarlas mutilaría la serie que se quiere pronosticar y, peor, la mutilaría de forma no aleatoria: el canal de venta sin cliente registrado probablemente no se comporta igual que el canal mayorista. **Se quedan**.

Para la **Parte 6**: ahí la pregunta es *quién* compró, y una venta sin cliente no se le puede asignar a nadie. Un cliente anónimo no tiene recencia ni frecuencia. **Ahí sí se excluyen**, y por eso la función `limpiar` solo las *marca* en vez de eliminarlas: la decisión se toma donde se conoce el uso.

1.3 La bitácora de limpieza

Tabla 6: 1.3 Bitácora de limpieza. El orden en que se aplican las reglas es parte de la bitácora.

orden	regla	filas eliminadas	monto (£)
1	R1 duplicados exactos	5 268	21 740.98
2	R2 facturas con prefijo distinto de digito o C	3	-11 062.06
3	R3 StockCode que no es venta al cliente	149	-239 669.22
4	R4 precio unitario <= 0	2 510	0.00
5	R5 cantidad negativa sin factura de cancelacion	0	0.00
6	R6 filas sin CustomerID (SE QUEDAN)	0	0.00
7	TOTAL	7 930	-228 990.30

Qué leer: R5 elimina cero filas porque R4 ya se llevó las 1 336 filas de cantidad negativa, que tenían todas precio cero. La tabla siguiente muestra qué pasa si se invierte el orden.

El orden cambia los conteos. El enunciado lo advierte y conviene demostrarlo, no solo mencionarlo. Si la regla de cantidades negativas se aplica *antes* que la de precio cero, en lugar de después:

Tabla 7: 1.3 Las mismas reglas con R4 y R5 intercambiadas.

orden	regla	filas eliminadas	monto (£)
1	R1 duplicados exactos	5 268	21 740.98
2	R2 prefijo distinto de digito o C	3	-11 062.06
3	R3 StockCode que no es venta	149	-239 669.22
4	R5 cantidad negativa sin cancelacion (ADELANTADA)	1 336	0.00
5	R4 precio <= 0 (ATRASADA)	1 174	0.00

Qué leer: la misma regla elimina 1 336 filas aquí y 0 en la tabla anterior. El conjunto final es idéntico (533 979 filas), pero la bitácora cuenta otra historia: sin el orden documentado no es reproducible.

La misma regla elimina 1,336 filas en un orden y 0 en el otro, porque las 1,336 filas de cantidad negativa tienen todas precio cero y quien llegue primero se las lleva. El conjunto final es idéntico en ambos órdenes (533,979 filas), pero la bitácora cuenta dos historias distintas. Es un buen recordatorio de que una bitácora de limpieza sin el orden documentado no es reproducible.

1.4 Las seis líneas más grandes

Son tres pares, no seis eventos independientes, y los tres cuentan la misma historia:

1. `581483` / `C581484`, 80,995 unidades de `PAPER CRAFT, LITTLE BIRDIE` por £168,470. La venta se registra el 9 de diciembre a las 09:15 y se cancela a las 09:27, doce minutos después, el mismo día. Es el pedido más grande de todo el archivo y nunca existió de verdad.

Tabla 8: 1.4 Las seis líneas de mayor |Quantity × UnitPrice| *antes* de limpiar.

factura	descripción	cantidad	monto (£)	fecha y hora	sobrevive
C581484	PAPER CRAFT , LITTLE BIRDIE	-80 995	-168 469.60	2011-12-09 09:27	sí
581483	PAPER CRAFT , LITTLE BIRDIE	80 995	168 469.60	2011-12-09 09:15	sí
541431	MEDIUM CERAMIC TOP STORAGE JAR	74 215	77 183.60	2011-01-18 10:01	sí
C541433	MEDIUM CERAMIC TOP STORAGE JAR	-74 215	-77 183.60	2011-01-18 10:17	sí
556444	PICNIC BASKET WICKER 60 PIECES	60	38 970.00	2011-06-10 15:28	sí
C556445	Manual	-1	-38 970.00	2011-06-10 15:31	sí

Qué leer: son tres pares venta/cancelación, no seis eventos. Las seis sobreviven a la limpieza porque ninguna es un error; lo que las resuelve es netear por día, ya que en los tres casos la cancelación ocurre el mismo día (12, 16 y 3 minutos después).

2. `541431` / `C541433`, 74,215 tarros de cerámica por £77,184. Vendidos el 18 de enero a las 10:01, cancelados a las 10:17.

3. `556444` / `C556445`, una cesta de picnic por £38,970. Vendida el 10 de junio a las 15:28 y cancelada a las 15:31, pero *la cancelación viene como una línea* `Manual`, no como el mismo producto.

¿Su limpieza las resuelve? **No, y no debería.** Las seis líneas sobreviven a las seis reglas, porque las seis son ventas o cancelaciones legítimas: tienen precio positivo, código de producto válido y factura con formato correcto. No hay nada en la línea, vista de forma aislada, que permita señalarla como error. Una regla del tipo "elimine cantidades mayores a 10,000" sería arbitraria y borraría también pedidos mayoristas genuinos.

¿Las resuelve el hecho de netear por día? **Sí, en los tres casos, y de forma exacta.** En los tres pares la venta y su cancelación caen en el *mismo día* calendario (separadas por 12 minutos, 16 minutos y 3 minutos respectivamente), así que al sumar todas las líneas del día los montos se anulan y la serie diaria ni se entera. Esto es exactamente lo que justifica la definición de venta neta diaria del enunciado.

Vale la pena notar dónde *no* funcionaría: si una cancelación ocurriera varios días después de la venta, el neteo diario dejaría un pico positivo un día y un hoyo negativo otro, y ninguno de los dos sería real. Con estos datos los pares grandes son todos del mismo día, pero no hay garantía de que lo sean en general.

1.5 La función `limpiar`

Toda la limpieza está escrita como una sola función `limpiar(df)` en `src/limpieza.py`, su propio archivo, tal como pide el enunciado. Devuelve el `DataFrame` limpio con dos columnas nuevas (`monto` y `cancelacion`) y, opcionalmente, la bitácora. Se reusa tal cual en la Parte 6 y queda disponible para el Proyecto 1.

Tabla 9: 2.1–2.4 El calendario de la serie.

concepto	valor
primer dia	2010-12-01
ultimo dia de los datos	2011-12-09
dias calendario (inclusive)	374
dias con al menos una transaccion	305
dias sin transacciones	69
de ellos, sabados	53
de ellos, feriados bancarios	11
sin explicacion	5
serie final: dias en el calendario (sin el ultimo dia)	373
serie final: dias abiertos	304
venta neta total de la serie (GBP)	9944626.32

Qué leer: de 374 días calendario solo 305 tuvieron ventas. Los 53 sábados son el hallazgo que fija $s = 6$ en la Parte 4.

Parte 2: El calendario

2.1 Cuántos días hay y cuántos se usaron

Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011, ambos inclusive, hay 374 **días calendario**. De esos, 305 **tuvieron al menos una transacción** y 69 no tuvieron ninguna.

2.2 Los días sin transacciones

¿Qué día de la semana no abre la tienda? El **sábado**. De los 69 días sin transacciones, 53 son sábados, y no hay ni un solo sábado con ventas en todo el año. Vale la pena subrayar que la tienda **sí abre los domingos** (50 domingos con ventas), que es lo contrario de lo que uno supondría por costumbre. **Esto tiene una consecuencia directa sobre el resto de la tarea: la semana comercial tiene seis días, no siete, y por eso el período estacional de los modelos SARIMA de la Parte 4 es $s = 6$ y no $s = 7$.**

¿Qué otros días faltan y qué fueron? Los 16 restantes se reparten entre 11 feriados bancarios del Reino Unido y 5 días del cierre navideño de fin de año (del 30 de diciembre de 2010 al 2 de enero de 2011, más el domingo de Pascua).

¿Cuáles de los que encontraron son móviles? Tres, y es justo la advertencia de FPP2 §12.1 sobre los feriados móviles:

- El **Viernes Santo** (22 de abril de 2011) y el **Lunes de Pascua** (25 de abril) se mueven con la Pascua, que puede caer entre el 22 de marzo y el 25 de abril. En 2011 cayó muy tarde; en 2012 fue el 6 y el 9 de abril. Un modelo que aprenda "la tercera semana de abril se vende poco" con un año de datos estará equivocado al año siguiente.
- La **boda real** del 29 de abril de 2011 es peor que móvil: es **irrepetible**. Fue un feriado extraordinario decretado para ese año. No hay forma de que ningún modelo lo anticipe, y tampoco debería intentarlo.

Los demás son fijos por regla (primer lunes de mayo, último lunes de mayo, último lunes de agosto) o por fecha (Navidad, Boxing Day), así que sí se pueden poner en el calendario por adelantado. Esa

Tabla 10: 2.2 Los días sin transacciones que *no* son sábado. Los 53 sábados se omiten de la tabla por brevedad.

fecha	día	motivo	tipo
2010-12-24	viernes	feriado bancario: Nochebuena (la tienda cierra	fijo
2010-12-26	domingo	feriado bancario: Boxing Day	fijo
2010-12-27	lunes	feriado bancario: Navidad (dia sustituto)	fijo
2010-12-28	martes	feriado bancario: Boxing Day (dia sustituto)	fijo
2010-12-29	miercoles	sin explicacion en el calendario	—
2010-12-30	jueves	sin explicacion en el calendario	—
2010-12-31	viernes	sin explicacion en el calendario	—
2011-01-02	domingo	sin explicacion en el calendario	—
2011-01-03	lunes	feriado bancario: Ano Nuevo (dia sustituto)	fijo
2011-04-22	viernes	feriado bancario: Viernes Santo	**MOVIL**
2011-04-24	domingo	sin explicacion en el calendario	—
2011-04-25	lunes	feriado bancario: Lunes de Pascua	**MOVIL**
2011-04-29	viernes	feriado bancario: Boda real (feriado extraordi	**irrepetible**
2011-05-02	lunes	feriado bancario: Early May Bank Holiday	fijo (primer lunes de mayo)
2011-05-30	lunes	feriado bancario: Spring Bank Holiday	fijo (ultimo lunes de mayo)
2011-08-29	lunes	feriado bancario: Summer Bank Holiday	fijo (ultimo lunes de agosto)

Qué leer: tres de los feriados son móviles o irrepetibles. La Pascua se mueve hasta un mes entre años y la boda real de 2011 no se repite nunca, así que ningún modelo entrenado con un año de datos puede anticiparlos.

es la razón por la cual, en la Parte 5, se permite saber de antemano qué días futuros están abiertos: es información de calendario, no información del futuro.

2.3 *¿Un día sin transacciones es un cero o un dato faltante?*

Depende de la pregunta que se le haga a la serie, y las dos lecturas son correctas en contextos distintos.

Debe ser cero cuando se mide dinero. Si la pregunta es "£cuánto vendimos esta semana" o "£cuánto vendimos en noviembre", el sábado aportó exactamente cero libras. Un faltante obligaría a inventar un número o a reportar la suma de seis días como si fuera de siete. Por eso en el inciso 3.1 la media móvil centrada de siete días se calcula *rellenando los días cerrados con cero*: se busca el nivel de ingreso de la semana calendario, y un sábado cerrado contribuye cero a ese nivel.

Debe ser faltante cuando se mide comportamiento. Si la pregunta es "£cuánto vende un día típico" o "£qué tan grande es la autocorrelación de un día al siguiente", meter los sábados como ceros es dañino. Jalarían la media hacia abajo, inflarían la varianza y, sobre todo, meterían una estacionalidad artificial de período 7 que no describe el negocio sino el horario. El sábado no es un día de venta cero: es un día que no existe para la tienda. Por eso toda la modelación de las Partes 3.3 a 5 trabaja sobre **días abiertos, una fila por día**, y los días cerrados quedan marcados como faltantes en el calendario completo.

2.4 *¿Está completo el último día?*

No. El 9 de diciembre de 2011 la última factura es de las **12:50**, mientras que en el resto de los días la última factura es, en mediana, de las **17:00** y nunca antes de las **15:00**. El archivo se cortó a la

mitad de la jornada: la venta registrada (£32,112) es la de media mañana, no la del día.

¿Qué hacen con él? **Se descarta.** Dejarlo sería meter un dato bajo que no refleja una caída de la demanda sino el final del archivo, y el 8 de diciembre es de todas formas el último día que el enunciado manda evaluar. La alternativa de escalarlo (multiplicarlo por la proporción típica de venta que ocurre después de mediodía) inventaría un dato, y para un solo día al final de la serie no vale la pena el riesgo.

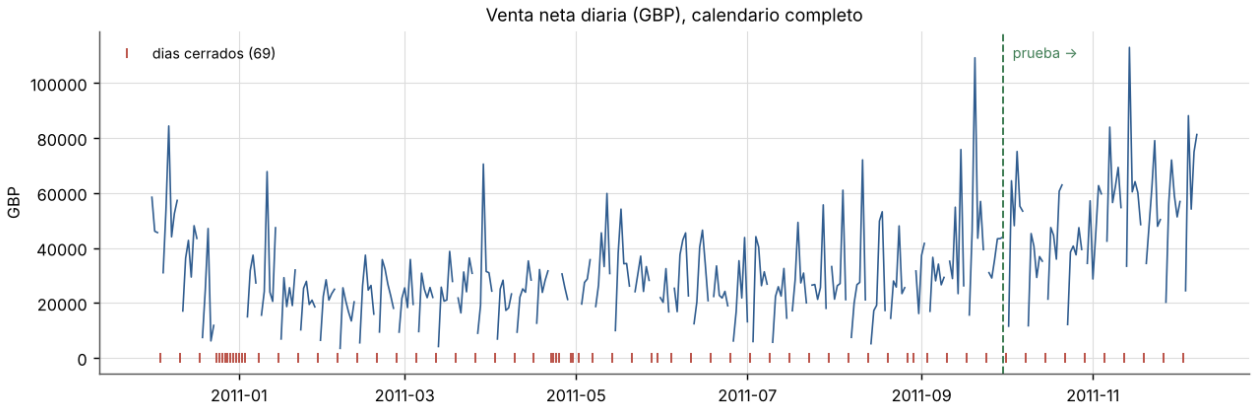


Figura 3: La serie de venta neta diaria sobre el calendario completo. **Qué muestra:** los 303 días del calendario tras descartar el último, con los días cerrados marcados abajo en rojo y la línea verde separando entrenamiento de prueba. **Por qué importa:** se ven de un vistazo los tres rasgos que gobiernan el resto de la tarea: el hueco largo de fin de año, el diente de sierra semanal, y la subida clara a partir de septiembre que hace que el período de prueba sea más difícil que el entrenamiento.

De aquí en adelante se trabaja con la serie diaria sobre el calendario completo, con los días cerrados marcados como faltantes y sin el último día. **Entrenamiento** es todo hasta el 30 de septiembre de 2011 (245 días abiertos) y **prueba** son los días abiertos del 3 de octubre al 8 de diciembre (58 días evaluados).

Parte 3: Tendencia, estacionalidad y autocorrelación

Lo que hacen 3.1 y 3.2 es una *descomposición clásica multiplicativa*: serie = tendencia × estacionalidad × resto.

3.1 Tendencia

¿Por qué 7 y no 5 ni 30? Porque siete es exactamente el largo del ciclo que se quiere eliminar. La semana calendario dura siete días, así que una media de siete días consecutivos contiene cada día de la semana exactamente una vez: el jueves bueno y el domingo malo entran con el mismo peso y el efecto del día de la semana se cancela aritméticamente, no por aproximación. Con cinco días la ventana contendría dos jueves en unas posiciones y ninguno en otras, así que la media móvil heredaría un residuo del propio patrón semanal que pretende quitar. Con treinta días sí se cancelaría el efecto semanal (aproximadamente, porque 30 no es múltiplo de 7), pero la ventana sería tan ancha que también alisaría lo que interesa conservar: la subida de noviembre quedaría aplastada y desplazada. La regla general es que la ventana se escoge igual al período estacional, ni más ni menos.

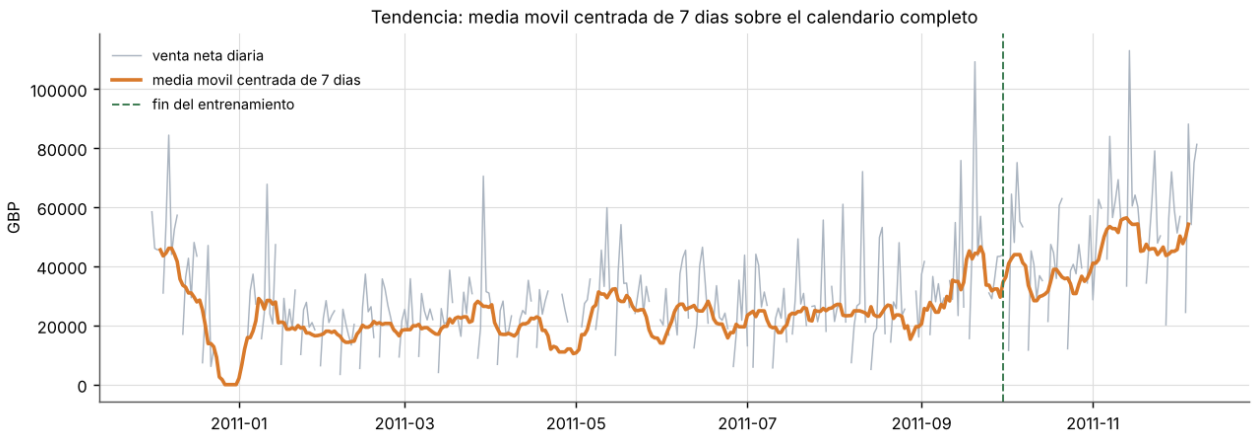


Figura 4: Media móvil centrada de siete días sobre el calendario completo, con los días cerrados rellenados con cero. **Qué muestra:** en gris la venta diaria, que sube y baja violentamente; en naranja la media móvil, que se queda con el nivel. **Por qué importa:** el diente de sierra diario desaparece por completo, y lo que queda es una tendencia plana alrededor de £20,000 de enero a julio que empieza a subir en agosto y se dispara en noviembre. El hoyo de finales de diciembre no es una caída de la demanda: es la tienda cerrada nueve días, y la media móvil lo registra como ceros.

¿Por qué centrada? Para que la tendencia no quede corrida en el tiempo. Una media móvil hacia atrás asigna al día t el promedio de los siete días que terminan en t, es decir el nivel del centro de esa ventana, que es $t-3$. Eso retrasa toda la curva tres días y haría parecer que la subida de noviembre empezó después de cuando realmente empezó. Centrarla la alinea con la serie. **El precio de centrarla es justamente lo que la vuelve ilegal como predictor**: para calcular la tendencia del día t hay que conocer y_{t+1}, y_{t+2} y y_{t+3}, que aún no han ocurrido. Esta es la trampa del inciso 5.4 y aquí ya queda sembrada.

La tendencia en dos o tres oraciones. El nivel se mantiene notablemente plano alrededor de £20,000 diarios desde enero hasta julio, con oscilaciones pero sin dirección. A partir de agosto empieza una subida sostenida que lo lleva a unos £30,000 al cerrar septiembre, y que se acelera fuerte en octubre y noviembre hasta un máximo de £56,412 el 13 de noviembre: es la temporada navideña de una tienda de artículos de regalo que vende casi todo a mayoristas, los cuales se abastecen con semanas de anticipación. **La consecuencia práctica es incomoda y conviene decirla desde ya: el período de prueba cae íntegramente sobre el tramo más alto y más inclinado de la serie, así que cualquier modelo entrenado solo con datos hasta septiembre va a quedarse corto.** Eso es exactamente lo que se observa en la Parte 5.

3.2 Estacionalidad

¿Qué días venden más? **Jueves** (índice 1.558) y **martes** (1.547), casi empatados, seguidos de miércoles (1.235), lunes (1.169) y viernes (1.125). El **domingo** es con mucho el más flojo: 0.570, menos de la mitad del jueves. El patrón tiene sentido para un negocio mayorista: los compradores profesionales hacen sus pedidos entre semana, con un pico a mitad de semana, y el domingo apenas entra el goteo de pedidos web de consumidores finales.

Tabla 11: 3.2 Índice estacional por día de la semana, calculado solo sobre el entrenamiento.

día	índice y_t/MA_t	desv. est.	n días	normalizado
lunes	1.1688	0.3239	37	0.9736
martes	1.5471	0.5434	42	1.2887
miercoles	1.2353	0.3866	42	1.0290
jueves	1.5579	0.4952	42	1.2977
viernes	1.1245	0.3193	39	0.9366
domingo	0.5695	0.2997	40	0.4744

Qué leer: jueves y martes venden más del triple que el domingo. El promedio de los seis índices es 1.2005 y no 1 porque el denominador promedia siete días calendario de los cuales uno es un sábado cerrado que entra como cero, lo que lo subestima por un factor de 6/7.

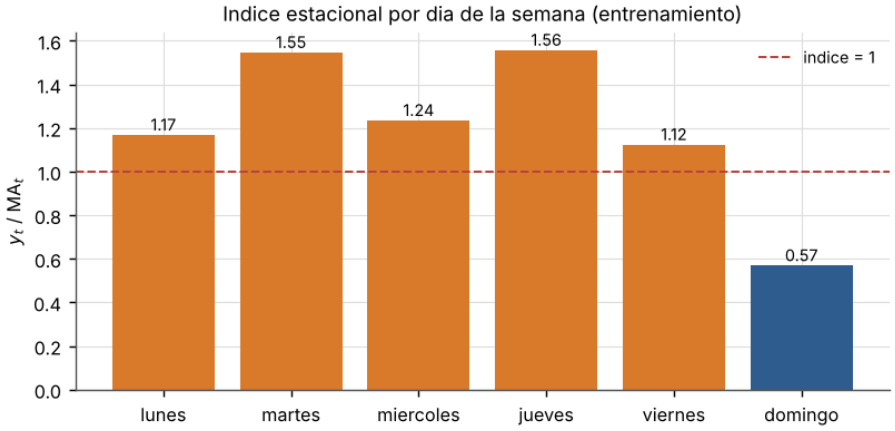


Figura 5: Índice estacional de cada día de la semana: el promedio, sobre el entrenamiento, del cociente y_t/MA_t. **Qué muestra:** el jueves y el martes venden alrededor de 1.55 veces el nivel de la semana; el domingo apenas 0.57. **Por qué importa:** la diferencia entre el mejor y el peor día es de casi tres a uno, así que cualquier modelo que ignore el día de la semana está dejando sobre la mesa la fuente de variación más grande y más predecible de la serie.

¿Por qué el promedio de los seis índices no es 1? El promedio es 1.200,5, no 1, y la razón es puramente aritmética, no un error. El denominador MA_t es un promedio sobre **siete** días calendario, pero uno de esos siete es un sábado cerrado que entra como **cero**. Entonces MA_t reparte la venta de seis días entre siete casillas, con lo que subestima sistemáticamente el nivel de un día abierto por un factor de 6/7. Al dividir cada día abierto entre ese denominador demasiado pequeño, todos los cocientes salen inflados por aproximadamente $7/6 = 1.166{,}7$. El valor observado de 1.200,5 es cercano a esa cifra; la diferencia que queda se debe a los feriados (que añaden más ceros al denominador en ciertas semanas) y a que el promedio de cocientes no es el cociente de promedios. La columna `indice_normalizado` de la tabla reescala los seis índices para que promedien 1 y permite leerlos como "porcentaje respecto a un día abierto promedio".

3.3 Autocorrelación

La función r_k está implementada a mano con `numpy`, es la misma de la Parte 0, y se aplica sobre los 245 **días abiertos del entrenamiento, una fila por día, sin calendario**.

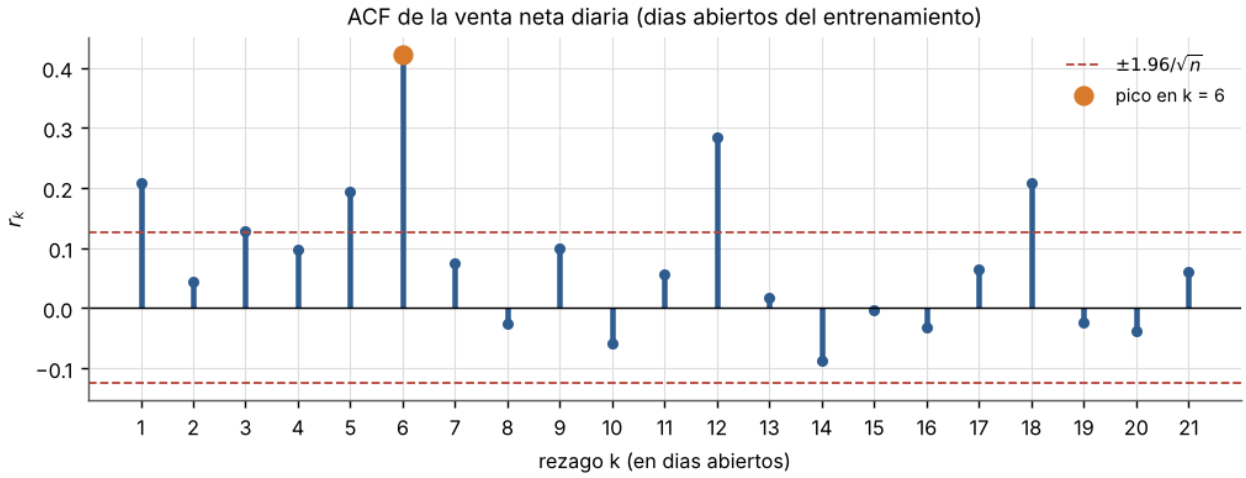


Figura 6: ACF de la venta neta diaria sobre los días abiertos del entrenamiento, con las bandas $\pm 1.96/\sqrt{n}$. **Qué muestra:** seis de 21 rezagos se salen de las bandas, y el patrón no es aleatorio: los picos están en 6, 12 y 18, que son múltiplos exactos de seis. **Por qué importa:** esos picos son la firma de una estacionalidad de período 6 en la escala de días abiertos, y son la evidencia empírica que justifica usar $s = 6$ en los modelos SARIMA de la Parte 4.

¿Cuántos rezagos se salen? **Seis de** 21: los rezagos 1, 3, 5, 6, 12 y 18, contra la banda $\pm 0.125{,}2$. Si la serie fuera ruido blanco se esperaría que se saliera aproximadamente uno ($21 \times 0.05 \approx 1.05$).

¿Pasa la prueba de retardo 1 de la Tarea 2? **No, la reprueba.** $r_1 = 0.209{,}2$, bastante por encima de 0.125,2. A diferencia del caso semanal simulado de la Parte 0.4, que sí la pasaba, aquí hasta la prueba más miope detecta que algo pasa.

¿En qué rezago está el pico y cuántos días calendario representa? El pico está en $k = 6$, con $r_6 = 0.422{,}4$, el doble que cualquier otro. Y seis días abiertos son **siete días calendario**: se verificó directamente sobre las fechas y la mediana de la distancia calendario entre un día abierto y el sexto

anterior es exactamente 7 días (mínimo 7, máximo 18 en las semanas con feriados). Es decir, el pico en el rezago 6 es **el mismo día de la semana de la semana anterior**. Los picos secundarios en 12 y 18 son dos y tres semanas atrás. Esta es la traducción exacta del índice estacional de 3.2 al lenguaje de la ACF, y es la razón por la que la parte estacional de los modelos SARIMA usa $s = 6$: en la escala en que se modela, que es días abiertos, la semana mide seis.

Tabla 12: 3.3 Ljung–Box sobre la venta neta de los 245 días abiertos del entrenamiento.

m	$Q(m)$	**gl**	**valor-p**	**rechaza al 5 %**
6	72.53	6	1.24e-13	**sí**
12	99.38	12	7.77e-16	**sí**

Qué leer: los dos criterios de m que discuten FPP2 y Tsay coinciden sin ambigüedad: la serie no es ruido blanco.

Ljung–Box. Ambas pruebas rechazan de forma aplastante: $Q(6) = 72.53$ con $p = 1.2 \times 10^{-13}$ y $Q(12) = 99.38$ con $p = 7.8 \times 10^{-16}$. Los dos criterios de m que discuten FPP2 y Tsay coinciden sin ambigüedad.

3.3(b) *¿Cuánto de esa autocorrelación es memoria y cuánto es media no constante?* Con lo visto en la Parte 0, hay razones para sospechar de ambas y la ACF por sí sola no las distingue.

Hay evidencia fuerte de **media no constante** por dos vías. La primera es la estacionalidad: 3.2 ya mostró que la media de un jueves es casi el triple que la de un domingo, así que $\bar{y}$ no es la media de nadie, exactamente el mecanismo del caso semanal de 0.4. La segunda es la tendencia: 3.1 mostró que el nivel sube claramente a partir de agosto, que es el mecanismo del caso de tendencia lineal de 0.4. Los picos en 6, 12 y 18 son la firma característica de lo primero.

Pero también hay señales de **memoria**: $r_1 = 0.209{,}2$ es grande y positivo, y el rezago 1 no es múltiplo de seis, así que la estacionalidad semanal no lo explica de forma obvia. Además la ACF no cae rápido a cero después del rezago 6, lo que sugiere algo más que estacionalidad pura.

La forma honesta de separarlos es la receta clásica, que es justo lo que hace la Parte 4: primero se quita la media no constante (el día de la semana y la tendencia) y después se mira qué autocorrelación le queda al residuo. Lo que sobreviva a ese filtro sí es memoria.

Parte 4: Del AR(1) al SARIMA

Toda esta parte trabaja sobre los 245 días abiertos del entrenamiento como una fila por día.

4.1 Quitar el día de la semana

Los coeficientes son la venta promedio de cada día de la semana en libras y reproducen el orden del inciso 3.2: jueves (£36,094) y martes (£35,966) arriba, domingo (£13,819) muy abajo. El R^2 es 0.260,6: el día de la semana por sí solo explica algo más de una cuarta parte de la variación diaria.

¿Qué cambió respecto a 3.3? Dos cosas. La estacionalidad se redujo mucho: r_6 bajó de 0.422,4 a 0.222,4, así que las indicadoras de día de la semana se llevaron cerca de la mitad del pico semanal (no todo, porque el efecto del día de la semana es multiplicativo sobre un nivel que cambia, y el OLS lo

Tabla 13: 4.1 OLS de la venta contra indicadoras de día de la semana, sin intercepto. $R^2 = 0.2606$.

día	coeficiente (£)	n días
lunes	27 770.41	37
martes	35 966.22	42
miercoles	28 504.25	43
jueves	36 093.53	43
viernes	27 106.35	40
domingo	13 819.45	40

Qué leer: los coeficientes son la venta promedio de cada día y reproducen el orden de los índices de 3.2. El modelo le asigna el mismo valor a todos los jueves del año, lo que deja la tendencia entera dentro de los residuos.

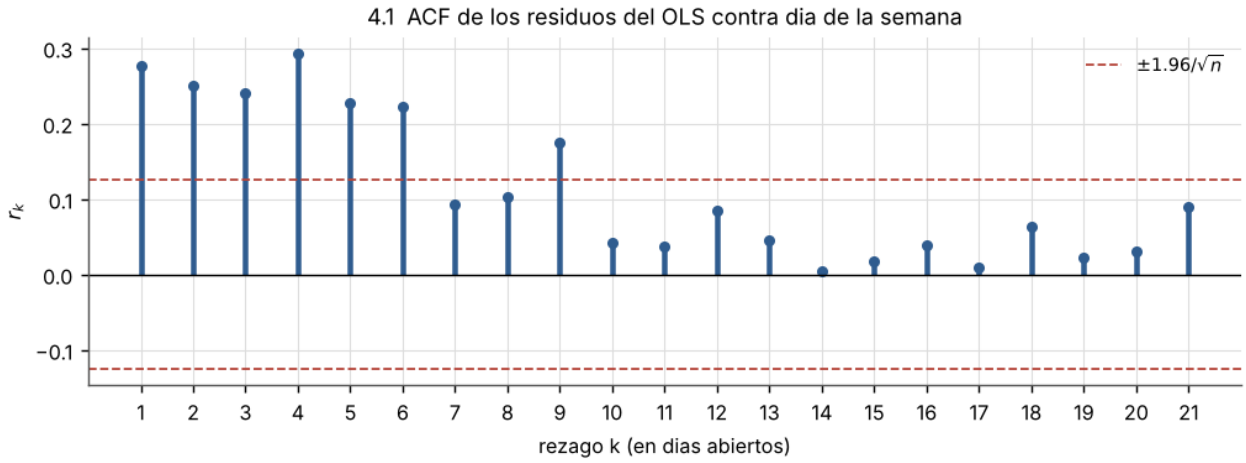


Figura 7: ACF de los residuos e_t del OLS contra indicadoras de día de la semana. **Qué muestra:** el pico gigante del rezago 6 desapareció (bajó de 0.42 a 0.22) y en su lugar quedaron siete rezagos fuera de banda, los seis primeros consecutivos y decrecientes. **Por qué importa:** esta forma es la de una serie con la media todavía moviéndose, no la de un AR(1).

está modelando como aditivo y constante). Pero el número de rezagos fuera de banda *subió* de seis a siete, y ahora los rezagos 1 a 6 están *todos* fuera: r_1 incluso creció, de 0.209,2 a 0.275,9. Quitar la estacionalidad destapó la estructura que estaba debajo.

Comparen la forma de esta ACF con las de la Parte 0: ¿decae como ϕ^k, como un AR(1), o se parece más a la del proceso con tendencia? **Se parece mucho más a la del proceso con tendencia.** Un AR(1) con $\phi \approx 0.28$ (que es lo que sugiere r_1) tendría $r_2 \approx 0.08$, $r_3 \approx 0.02$ y prácticamente nada de ahí en adelante: la ACF se hunde dentro de las bandas al segundo o tercer rezago. Lo que se observa es un decaimiento *mucho más lento*, con seis rezagos consecutivos fuera de banda. Esa caida lenta es precisamente la pista visual que menciona FPP2 §8.1 para una serie **no estacionaria**: la ACF de una serie estacionaria cae a cero rápido, la de una no estacionaria baja despacio.

¿Qué le falta a este modelo? Le falta la **tendencia**, que es lo que 3.1 mostró y lo que la ACF está gritando. El OLS contra indicadoras de día de la semana le asigna a cada jueves del año el mismo valor ajustado, £36,094, sin importar que los jueves de febrero vendieran alrededor de £20,000 y los de noviembre más de £55,000. Todos los residuos de la primera mitad del año quedan negativos y los de la segunda positivos, y residuos vecinos se parecen entre sí por esa razón y no porque haya memoria. Es exactamente el mecanismo de la tendencia lineal de 0.4. También le falta permitir que el tamaño del efecto semanal crezca con el nivel, que es lo que motiva trabajar en logaritmos en 4.3.

4.2 Un AR(1) para la memoria que queda

Regresando e_t contra e_{t-1} por OLS se obtiene $\hat{\phi} = 0.277{,}9$ (con $\hat{c} = -103.5$, prácticamente cero como corresponde a residuos de una regresión con indicadoras completas).

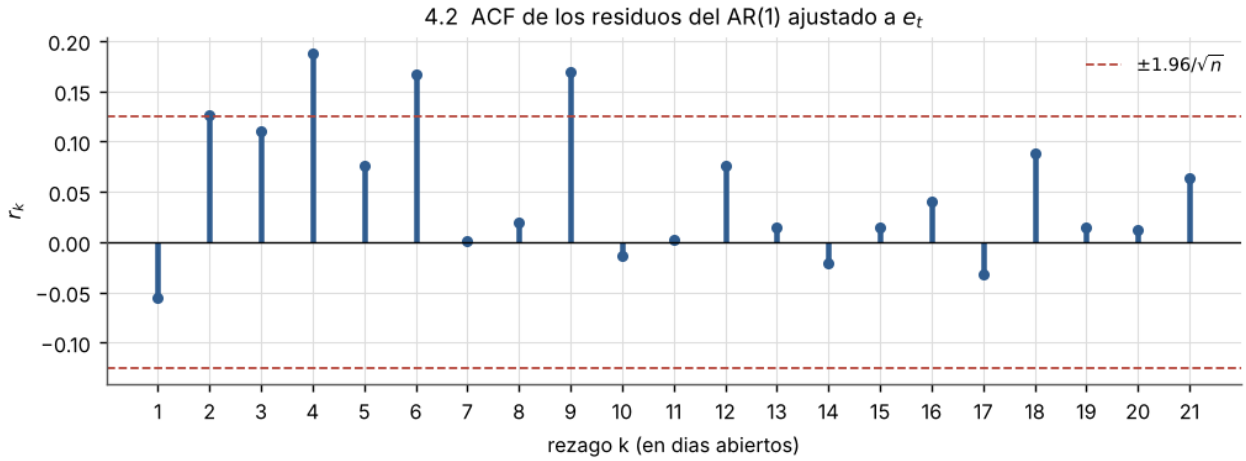


Figura 8: ACF de los residuos $u_t = e_t - \hat{c} - \hat{\phi} e_{t-1}$. **Qué muestra:** el AR(1) limpió el rezago 1, que ya está dentro de las bandas, pero dejó afuera los rezagos 2, 4, 6 y 9. **Por qué importa:** el rezago 6 sigue vivo, y eso es estacionalidad, que un AR(1) no tiene cómo capturar.

¿Ya parecen ruido blanco? **No.** $Q(6) = 25.04$ con 5 grados de libertad da $p = 1.4 \times 10^{-4}$, y $Q(12) = 33.95$ con 11 grados de libertad da $p = 3.7 \times 10^{-4}$ (se descuenta un grado de libertad en cada caso por el ϕ estimado, siguiendo Tsay §2.4). Ambas rechazan con holgura.

Tabla 14: 4.2 AR(1) ajustado por OLS a los residuos e_t del inciso 4.1, y Ljung–Box sobre sus residuos u_t (un grado de libertad menos por el ϕ estimado).

cantidad	valor
c	-103.51
phi	0.2779
desv_est_residuos_u	11 901.04
LjungBox Q(6)	25.0364
LjungBox Q(6) gl	5.0000
LjungBox Q(6) valor_p	0.0001
LjungBox Q(12)	33.9542
LjungBox Q(12) gl	11.0000
LjungBox Q(12) valor_p	0.0004

Qué leer: $\hat{\phi} = 0.278$ limpia el rezago 1, pero ambas pruebas siguen rechazando: quedan fuera de banda los rezagos 2, 4, 6 y 9. Un AR(1) implica $\rho_6 = 0.28^6 \approx 0.0005$, o sea que predice que no hay nada en el rezago 6, y sí lo hay.

¿Qué rezagos siguen fuera de las bandas? Los rezagos **2, 4, 6 y 9**. El 1 sí quedó limpio, que es justo lo que un AR(1) sabe hacer.

¿Alcanzó un AR(1) para lo que encontraron en 4.1? **No, y no podía alcanzar.** El AR(1) tiene un solo parámetro y lo gasta todo en el rezago 1. Pero el problema de 4.1 no era el rezago 1: era un decaimiento lento que delata una media que se mueve, y un pico estacional en el rezago 6 que sobrevivió a las indicadoras. Un AR(1) con $\hat{\phi} = 0.28$ implica $\rho_6 = 0.28^6 \approx 0.000{,}5$, o sea que el modelo predice que *no hay* nada en el rezago 6, mientras los datos muestran que sí lo hay. Se necesitan dos herramientas que el AR(1) no tiene: un término **estacional** que mire directamente el rezago 6, y una **diferenciación** que se encargue de la media que se mueve. Eso es exactamente la familia SARIMA.

4.3 SARIMA

Siguiendo el enunciado, ambos modelos se ajustan sobre el **logaritmo** de la venta diaria, con $s = 6$, pasándole al estimador el arreglo de valores y no la serie con fechas.

¿Por qué $s = 6$ y no 7? Porque la serie que se modela es la de días *abiertos*, una fila por día, y la tienda cierra los sábados: entre un jueves y el jueves anterior hay seis filas, no siete. Esto no es una conjetura sino un hallazgo medido: el inciso 3.3 verificó que el pico de la ACF está en $k = 6$ y que esos seis días abiertos corresponden a siete días calendario. Si se usara $s = 7$ el término estacional apuntaría al *viernes* anterior cuando el día es jueves, y el modelo buscaría la estacionalidad donde no está.

¿Cuándo se rompe ese supuesto en estos datos? En las semanas con feriado. El supuesto de "seis filas = una semana" vale solo si cada semana aporta exactamente seis días abiertos, y eso falla en las 11 semanas con feriado bancario: en la semana de Pascua, por ejemplo, la tienda abrió cuatro días, así que el rezago 6 apunta a un día de la semana equivocado. La verificación empírica de 3.3 lo cuantifica: la distancia calendario del rezago 6 es de siete días en la mediana, pero llega a 18 en el peor caso. Es una aproximación, buena la mayor parte del año y mala alrededor de los feriados, y es parte del precio de modelar días abiertos como si fueran una rejilla regular.

¿Por qué el logaritmo? Por tres razones que apuntan en la misma dirección. Primero, la variabilidad de la serie crece con su nivel: en los meses planos las oscilaciones diarias son de unos pocos miles de libras y en noviembre son de decenas de miles. El logaritmo estabiliza esa varianza, que es justo el caso que FPP2 §3.2 describe para una transformación. Segundo, el efecto del día de la semana es *multiplicativo* (3.2 lo midió como un índice, no como un monto fijo), y en logaritmos un efecto multiplicativo se vuelve aditivo, que es lo que un modelo lineal sabe manejar. Tercero, el logaritmo garantiza que el pronóstico al deshacer la transformación sea positivo. Como se ajustó en logaritmos, para volver a libras se aplica `exp()` al pronóstico, sin corrección de sesgo, tal como indica el enunciado; con eso el pronóstico es la mediana condicional y no la media.

Tabla 15: 4.3 Los dos modelos SARIMA ajustados sobre log(venta diaria) con $s = 6$, por máxima verosimilitud exacta (filtro de Kalman).

modelo	$\hat{\phi}$	$\hat{\Phi}$	$\hat{\theta}$	$\hat{\Theta}$	$\hat{\mu}$	$\hat{\sigma}^2$	log-verosim.	conv.
S1 SARIMA(1,0,0)(1,0,0)_6 con con	0.1216	0.5296	—	—	10.1480	0.21677	-161.344	sí
S2 SARIMA(0,1,1)(0,1,1)_6 sin con	—	—	-0.9179	-0.6612	—	0.21364	-157.188	sí

Qué leer: en S1 el término estacional ($\hat{\Phi} = 0.53$) pesa mucho más que el regular ($\hat{\phi} = 0.12$), confirmando que el rezago 6 es el que importa. Ambos modelos convergieron ya con el `maxiter` por omisión; con `maxiter`=500 los parámetros son idénticos a cuatro decimales.

Convergencia. Se verificó `mle_retvals['converged']` en ambos modelos. Los dos convergieron ya con el `maxiter` por omisión, así que no hizo falta subirlo; por control se repitió el ajuste con `maxiter=500` y los parámetros resultaron idénticos hasta la cuarta cifra decimal y la log-verosimilitud coincide en los tres decimales reportados. En la Parte 5, donde ambos modelos se reajustan en cada origen móvil, se usó la configuración que convergió aquí y se verificó la convergencia en cada origen: S1 y S2 convergieron en los 22 orígenes de entrenamiento y en los 10 de prueba.

Los parámetros estimados son coherentes con el diagnóstico de 4.1 y 4.2. En S1 el término estacional domina ($\hat{\Phi} = 0.529{,}6$) sobre el regular ($\hat{\phi} = 0.121{,}6$): el modelo confirma que el rezago 6 importa mucho más que el rezago 1. En S2 ambos coeficientes MA son grandes y negativos ($\hat{\theta} = -0.917{,}9$, $\hat{\Theta} = -0.661{,}2$), que es la firma típica del modelo de aerolínea cuando las diferencias han sobre-diferenciado un poco la serie.

4.4 Diagnóstico

Tabla 16: 4.4 Ljung–Box sobre los residuos. En S2 se descartan los primeros 7 residuos, que son artefactos del arranque de las diferencias $(1-B)(1-B^6)$. Los grados de libertad bajan a $m-2$ en ambos modelos.

modelo	m	n residuos	$Q(m)$	gl	valor-p	ruido blanco
S1	6	245	9.72	4	0.0454	no
S1	12	245	23.36	10	0.0095	no
S2	6	231	4.31	4	0.3655	**sí**
S2	12	231	11.76	10	0.3015	**sí**

Qué leer: S2 es el único que deja residuos de ruido blanco. S1 es estacionario y supone una media fija que no existe, así que la tendencia de agosto en adelante se le queda en los residuos. Este resultado anticipa correctamente quién gana en la Parte 5.

En S2 se descartaron los primeros 7 residuos: las diferencias $(1-B)(1-B^6)$ se comen $d+Ds = 1+6 = 7$ observaciones y esos residuos son artefactos del arranque, no información sobre el modelo. En ambos

modelos los grados de libertad bajan a $m-2$ porque cada uno estima dos parámetros en la parte ARMA.

¿Cuál modelo deja residuos de ruido blanco? **S2, y solo S2.**

Para **S1**, $Q(6) = 9.72$ con 4 grados de libertad da $p = 0.045$ y $Q(12) = 23.36$ con 10 grados de libertad da $p = 0.009{,}5$. Ambas rechazan al 5 %, aunque $Q(6)$ lo hace por poco. Este es el único caso de toda la tarea donde la elección de m cambia la contundencia de la conclusión: con $m = 6$ el valor-p queda justo en el filo y con $m = 12$ el rechazo es claro. Como los dos apuntan en la misma dirección, la conclusión es que S1 **no** deja ruido blanco.

Para **S2**, $Q(6) = 4.31$ ($p = 0.365$) y $Q(12) = 11.76$ ($p = 0.301$). Ninguna se acerca a rechazar: los residuos de S2 son indistinguibles de ruido blanco.

La diferencia tiene una explicación clara y es la misma que se viene arrastrando desde 4.1. S1 es un modelo **estacionario**: supone que la serie oscila alrededor de una media fija, y esa suposición es falsa aquí porque el nivel sube a partir de agosto. Esa tendencia no modelada se queda en los residuos y aparece como autocorrelación. S2, en cambio, *diferencia* la serie en los dos sentidos, $(1-B)$ y $(1-B^6)$, y la diferenciación es precisamente el truco para series cuya media se mueve: le quita a la serie la obligación de volver a un nivel fijo. Por eso S2 puede seguir la subida y S1 no.

4.5 *¿Hacia dónde van los pronósticos?*

S1: hacia la media, y se queda ahí. S1 es estacionario, y un proceso estacionario olvida. Es el mismo argumento del AR(1) de la Parte 0 con $|\phi| < 1$: la influencia del último valor observado se multiplica por ϕ (y por Φ en la parte estacional) en cada paso hacia adelante, así que se desvanece geométricamente, y el pronóstico converge a la media incondicional del modelo. Los números lo muestran limpiamente: a un paso pronostica £29,402, a 30 pasos £26,124, y a 120 pasos £25,539, que es exactamente $\exp(\hat{\mu}) = £25{,}539$. De ahí ya no se mueve. Para horizontes largos, S1 no dice nada más interesante que "la venta típica".

S2: se va, sin límite. S2 no es estacionario, y por el lado contrario: con $d = 1$, la serie en niveles es una caminata aleatoria (con estructura MA encima), y una caminata aleatoria nunca olvida. El pronóstico no tiene una media a la cual regresar, así que arrastra indefinidamente el nivel y la pendiente que tenía al final de los datos. Los números: £29,118 a un paso, £61,148 a 30 pasos y £174,338 a 120 pasos, creciendo sin freno. Como los datos terminan en plena subida navideña, S2 extrapola esa subida para siempre, lo cual es razonable a unos pocos días y absurdo a seis meses. Además sus intervalos de predicción se abren indefinidamente, igual que la $\mathrm{Var}(Y_t) = t\sigma^2$ de la caminata aleatoria del inciso 0.1.

La moraleja práctica es que la ventaja de S2 en 4.4 y la que se verá en la Parte 5 es una ventaja *de horizonte corto*. Es el modelo correcto para pronosticar la próxima semana porque puede seguir el nivel que se mueve; sería el modelo equivocado para pronosticar el próximo año.

Parte 5: Pronóstico y fuga

5.1 Los seis modelos

Además de S1 y S2 se implementaron cuatro modelos más:

B1 La media histórica de los días abiertos. Un número constante.

B2 Naive estacional: el valor del mismo día de la semana abierto más reciente. Es el pronóstico de una caminata aleatoria estacional.

M1 OLS con una tendencia lineal en t e indicadoras de día de la semana.

M2 OLS con indicadoras de día de la semana y los rezagos y_{t-7} e y_{t-14}. Cuando alguno cae en día cerrado se usa el mismo día de la semana abierto más reciente; las filas que se quedan sin rezago al inicio no se usan para ajustar.

¿Por qué M2 puede usar y_{t-7} para pronosticar cualquiera de los siete días siguientes, pero no podría usar y_{t-1}? Porque el origen es un domingo y el objetivo más lejano es el domingo siguiente, siete días calendario después. Para ese objetivo, y_{t-7} es la venta del *domingo origen*, que ya está observada (el enunciado lo dice explícitamente: la venta del origen ya forma parte de lo observado). Para cualquier objetivo más cercano, y_{t-7} cae aún antes, así que con más razón ya se conoce. Es decir, el rezago 7 nunca cruza la frontera del presente.

Con y_{t-1} sería distinto. Para pronosticar el martes habría que conocer la venta del lunes, que todavía no ha ocurrido: está del lado del futuro. Usarla sería darle al modelo información que no tendría un usuario real el domingo por la noche, que es precisamente la definición de fuga. El rezago 7 funciona porque es, justamente, la distancia del ciclo que separa al origen de su objetivo más lejano.

¿Cómo le hace S1 para usar el rezago 1 de todas formas? Pronosticando de forma *recursiva*. S1 sí usa el rezago 1, pero para el horizonte 1 usa el valor *observado* del origen, y para el horizonte 2 en adelante sustituye el valor que no conoce por su propio pronóstico del paso anterior. No hace trampa: nunca mira un dato que no tiene, solo encadena sus propias predicciones. El precio es que el error se acumula, y por eso la calidad de los modelos recursivos se degrada conforme crece el horizonte.

5.2–5.3 Los tres estimados del error

Tabla 17: 5.2–5.3 MAE y RMSE en libras de los seis modelos, estimados de tres formas: (a) validación cruzada aleatoria de 5 *folds* sobre el entrenamiento con 10 semillas (media ± desviación estándar entre semillas), (b) origen móvil semanal dentro del entrenamiento con 22 orígenes de mayo a septiembre, (c) origen móvil semanal en la prueba con 10 orígenes, 58 días evaluados.

modelo	MAE (a)	RMSE (a)	MAE (b)	RMSE (b)	MAE (c)	RMSE (c)
B1	10 565 ±67	14 654	10 506	15 254	23 446	28 179
B2	—	—	11 634	15 949	14 655	18 957
M1	9 361 ±86	12 879	9 997	14 147	15 759	20 955
M2	8 522 ±106	12 007	9 480	13 675	15 648	20 393
S1	—	—	9 854	14 036	17 243	21 657
S2	—	—	10 304	14 325	12 817	16 217

Qué leer: (c) es la columna honesta y S2 gana por los dos criterios. (a) no aplica a B2, S1 y S2 porque los tres dependen del orden del tiempo. Y los tres estimados de adentro se quedan cortos: para M2, (b) subestima el error real en un 39 %.

¿Por qué no tiene sentido (a) para B2, S1 y S2? Porque la validación cruzada aleatoria *baraja las filas*, y esos tres modelos están definidos por el orden del tiempo. B2 necesita saber cuál es el día abierto más reciente del mismo día de la semana; si el conjunto de entrenamiento es un subconjunto aleatorio de días, "el más reciente" deja de estar bien definido y, lo que es peor, puede caer *después*

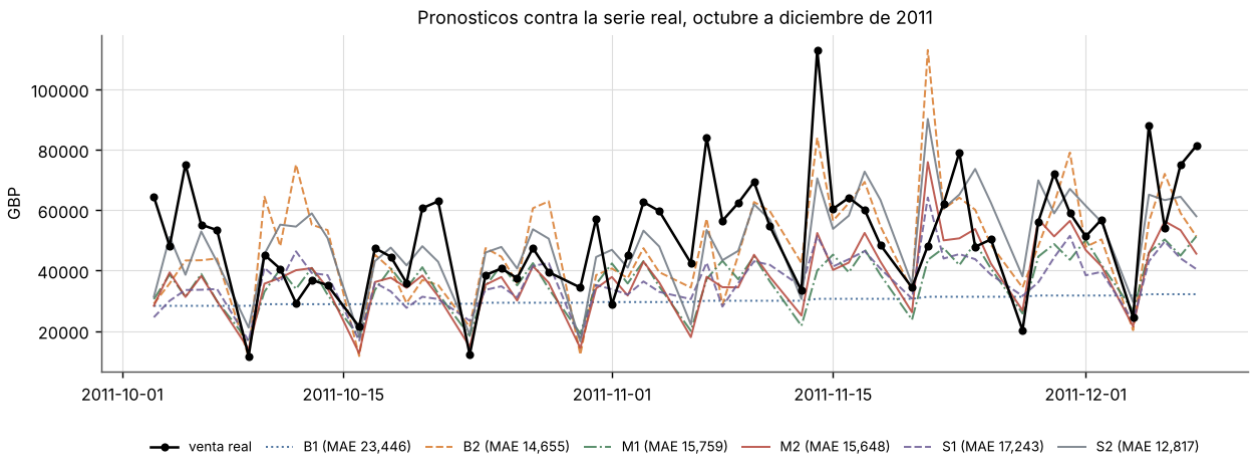


Figura 9: Pronósticos de los seis modelos contra la serie real en el período de prueba, con origen móvil semanal. **Qué muestra:** la línea negra es la venta real y las demás son los pronósticos. **Por qué importa:** se ve que *todos* los modelos van por debajo de la realidad durante casi todo el período, porque todos fueron entrenados con datos de un nivel más bajo. B1, la línea punteada horizontal cerca de £30,000, ni siquiera intenta seguir el movimiento. S2 es el que más se acerca al nivel alto de noviembre.

del día que se quiere predecir. S1 y S2 necesitan una serie contigua: el filtro de Kalman recorre las observaciones una tras otra y las diferencias $(1-B)(1-B^6)$ no significan nada si faltan filas al azar en medio. B1, M1 y M2, en cambio, son modelos de *fila*: su predicción para un día depende solo de las variables de esa fila, así que barajar no los rompe mecánicamente. (Que no los rompa mecánicamente no quiere decir que el resultado sea válido; de eso trata 5.5.)

¿Cuál de (a) y (b) se acerca más a (c)? ¿Alguna se acerca de verdad? **(b) se acerca más, pero ninguna se acerca de verdad.** Comparando sobre los modelos que admiten las tres estimaciones, M1 y M2: en (a) el MAE es de £9,361 y £8,522, en (b) sube a £9,997 y £9,480, y en (c) salta a £15,759 y £15,648. El origen móvil es un poco más pesimista que la validación cruzada, que es lo correcto, pero ambos se quedan cortísimos: (b) subestima el error de prueba en un 39 % para M2, y (a) en un 46 %. Para B1 la distancia es aún más brutal: £10,506 en (b) contra £23,446 en (c), más del doble. Las causas se separan en 5.5.

5.3 *¿Qué modelo gana en prueba?* **S2**, y gana por los dos criterios: MAE de £12,817 (el siguiente es B2 con £14,655) y RMSE de £16,217 (el siguiente es B2 con £18,957). El orden completo por MAE es S2 < B2 < M2 < M1 < S1 < B1.

Por qué gana. La respuesta está en el inciso 4.4 y en la figura. El período de prueba cae íntegramente sobre la subida navideña, así que el problema dominante no es capturar el patrón semanal (eso lo hacen casi todos) sino **seguir un nivel que sube**. S2 es el único modelo del conjunto que diferencia la serie, y diferenciar es exactamente lo que libera al pronóstico de tener que volver a una media fija: arrastra el nivel recién observado hacia adelante. Esto conecta directamente con 4.4: S2 fue también el único cuyos residuos pasaron Ljung–Box, y pasaron porque no le quedaba tendencia sin modelar. El diagnóstico de residuos anticipó correctamente quién ganaría en prueba.

El reverso lo confirma: **B1 es el peor con diferencia** (£23,446, casi el doble que S2) justamente porque es el modelo más anclado a la media histórica, un número constante calculado sobre un año cuyo nivel típico ya no aplica. Y **S1 queda quinto** (£17,243), peor que modelos mucho más simples,

por la misma razón: es estacionario y jala el pronóstico de vuelta hacia $\exp(\hat{\mu}) \approx$ £25,539 cuando la realidad anda por encima de £60,000. Es notable que **B2, un naive estacional sin ningún parámetro**, quede segundo y le gane a los dos modelos de regresión y a S1: cuando el nivel se mueve rápido, copiar el valor más reciente del mismo día de la semana es una estrategia difícil de superar.

5.4 La trampa

Un compañero propone agregar a M2 la media móvil centrada de siete días de la Parte 3 como predictor, porque "resume la tendencia". Se hizo.

Tabla 18: 5.4 La trampa: M2 con la media móvil *centrada* de 7 días agregada como predictor.

modelo	MAE (a)	RMSE (a)	MAE (b)	RMSE (b)	MAE (c)	RMSE (c)
M2	8 522	12 007	9 480	13 675	—	—
M2 + MA7 (ilegal)	7 683	10 374	8 585	11 640	**imposible**	—

Qué leer: el predictor ilegal mejora el MAE un 9.8 % en (a) y un 9.4 % en (b), y ninguna de las dos validaciones protesta. La única señal de alarma es que (c) no se puede calcular: MA_t necesita y_{t+1}, y_{t+2}, y_{t+3} y además contiene $y_t/7$, que es la propia respuesta.

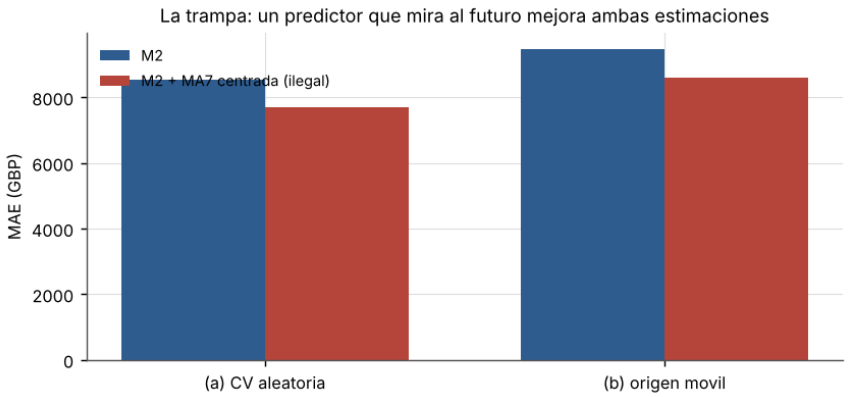


Figura 10: MAE de M2 con y sin la media móvil centrada como predictor. **Qué muestra:** el predictor ilegal baja el error en las dos formas de estimarlo. **Por qué importa:** ninguna de las dos validaciones emite señal de alarma. Un equipo que solo mirara estos números concluiría que acaba de mejorar su modelo.

¿Se ve mejor? **Sí, se ve claramente mejor, y ese es el problema.** En la validación cruzada aleatoria el MAE baja de £8,522 a £7,683, una mejora del 9.8 %. En el origen móvil dentro del entrenamiento baja de £9,480 a £8,585, una mejora del 9.4 %. El RMSE mejora aún más, un 14 % en ambos casos. Son mejoras del tamaño que uno celebraría en una reunión.

¿Por qué ese predictor es ilegal? Porque **mira al futuro**. La media móvil centrada de siete días en el día t es

$$\text{MA}_t = \frac{1}{7}\sum_{j=-3}^{3} y_{t+j} = \frac{y_{t-3} + y_{t-2} + y_{t-1} + y_t + y_{t+1} + y_{t+2} + y_{t+3}}{7}.$$

Tres de los siete sumandos, y_{t+1}, y_{t+2} e y_{t+3}, son días posteriores a t. Y el cuarto, y_t, *es la propia variable que se quiere pronosticar*: el predictor contiene $1/7$ de la respuesta. Nadie parado el domingo

por la noche puede calcular el MA centrado del miércoles siguiente, porque para eso necesitaría las ventas del jueves, viernes y sábado de esa semana. El modelo no está pronosticando: está leyendo una versión suavizada de la respuesta.

¿Por qué el origen móvil no *lo detecta si la media móvil se calcula una sola vez sobre toda la serie?* Porque el origen móvil solo controla *qué filas* entran al ajuste, no *cómo se construyeron las columnas*. La fuga ocurre antes, en el momento de calcular la columna `ma7` sobre la serie completa. Para cuando el origen móvil corta en el domingo y dice "entrena con esto, predice aquello", el valor de `ma7` de cada fila del futuro *ya trae dentro* la información de sus días vecinos. El corte temporal está bien hecho; la contaminación viaja *dentro* de una columna que el corte no toca.

Esta es la lección general y es la más importante de la Parte 5: una validación, por rigurosa que sea, solo protege contra la fuga que ocurre *después* del punto donde ella actúa. La regla práctica que se deriva es que toda transformación que use datos de varias filas (medias móviles, normalizaciones, imputaciones, codificaciones por promedio de la variable objetivo, selección de variables) debe recalcularse *dentro* de cada pliegue, nunca una sola vez sobre el conjunto completo. Si la columna se calcula una vez, el origen móvil se vuelve teatro.

¿Por qué no pueden calcular (c) sin hacer trampa? Porque para pronosticar el día t del período de prueba haría falta MA_t, y MA_t necesita y_{t+1}, y_{t+2} e y_{t+3}, que son días del período de prueba aún no observados en el momento del pronóstico. La única forma de producir un número para (c) sería ir a buscar esos valores al conjunto de prueba, que es precisamente lo que el conjunto de prueba existe para impedir. Por eso la celda correspondiente de la tabla está vacía y debe quedarse vacía: **la imposibilidad de calcular (c) es el síntoma de que el predictor no sirve**, y es la única de las tres validaciones que detecta el problema. Un predictor que no se puede calcular en producción no se puede usar en producción, por bien que luzca en el laboratorio.

5.5 Por qué todo lo estimado adentro se queda corto

Todas las estimaciones hechas dentro del entrenamiento se quedan cortas frente al error de prueba. Hay **dos causas distintas** y conviene separarlas porque tienen remedios opuestos.

Causa 1: cómo se partieron los datos. La validación cruzada aleatoria le permite al modelo entrenar con días *posteriores* a los que predice. Como la serie tiene tendencia y autocorrelación, un día de entrenamiento del 15 de septiembre le dice muchas cosas sobre un día de prueba del 14 de septiembre que no se sabrían de antemano. Además el horizonte efectivo de la validación cruzada es de cero días, mientras que el horizonte real va de uno a siete. Esto infla el optimismo de (a).

Esta causa sí se arregla con una mejor validación, y de hecho se ve arreglada en la tabla: al pasar de (a) a (b) el MAE de M2 sube de £8,522 a £9,480 y el de M1 de £9,361 a £9,997. Es decir, el origen móvil recupera alrededor de un 10 % de pesimismo que la validación cruzada aleatoria escondía. Esa diferencia es la medida limpia del sesgo introducido por partir mal.

Causa 2: la serie cambió. Pero incluso (b), que está bien construida, se queda a un 39 % del error real. Lo que falta no es un defecto del método de validación sino un hecho del mundo: entre mayo y septiembre la serie oscilaba alrededor de £20,000 a £30,000 diarios, y en noviembre andá por encima de £55,000. El período de prueba simplemente *no se parece* al período de entrenamiento. Ninguna

forma de partir los datos de mayo a septiembre puede revelar qué tan difícil es noviembre, porque noviembre no está ahí dentro.

Esta causa no se arregla con mejor validación. Se puede reconocer, se puede acotar (por ejemplo reservando siempre el tramo final como prueba, que es lo que hace el enunciado), se puede mitigar eligiendo modelos que se adapten rápido al nivel reciente, como S2, pero no se puede estimar desde adentro. Es la diferencia entre varianza de muestreo y cambio estructural.

Con un solo año de datos, ¿se puede estimar la estacionalidad anual? **No.** Para estimar un efecto estacional de período anual hay que observar varios ciclos: con uno solo, el "efecto noviembre" y "lo que pasó en noviembre de 2011" son exactamente el mismo número, y no hay forma de separar el patrón que se repite todos los años del evento particular de ese año. Formalmente, se tendría una observación por nivel del factor estacional: el parámetro no está identificado y su error estándar no se puede estimar.

Esto tiene una consecuencia incomoda y conviene ser explícito: la subida de noviembre que se observa en estos datos es casi con certeza estacionalidad navideña, pero **con este archivo no se puede demostrar**. Podría ser crecimiento del negocio, una campaña de marketing o un cliente mayorista grande que entró. Los tres se verían igual. Y por eso ninguno de los modelos de esta tarea tiene un término estacional anual: no se puede ajustar lo que no se puede identificar. Para capturarlo harían falta al menos tres o cuatro años, idealmente más, y aun entonces los feriados móviles del inciso 2.2 complicarían el asunto.

Parte 6: Detrás de la serie hay clientes

6.1 Construcción de R, F y M

Tabla 19: 6.1–6.5 Resumen del análisis RFM.

concepto	valor
clientes con transaccion antes del 1-oct	3658.0
clientes con M <= 0	54.0
valores distintos de F	48.0
compraron en la ventana	1845.0
tasa base de compra	0.5044
campeones	783.0
clientes nuevos en la ventana	723.0
venta de la ventana (GBP, clientes con ID)	2432839.69
AUC R (signo invertido)	0.6764
AUC F (crudo)	0.721
AUC M (crudo)	0.7093
AUC suma de los tres puntajes	0.7352

Qué leer: todo se calcula con transacciones anteriores al 1 de octubre; la ventana del 1 de octubre al 8 de diciembre solo se usa para definir la variable a predecir.

Usando solo las transacciones anteriores al 1 de octubre de 2011, y solo las filas limpias con `CustomerID`, hay 3,658 **clientes**.

¿Cuántos tienen $M \leq 0$ y qué hacen con ellos? Son 54 **clientes**, el 1.48 %, y son clientes que devolvieron más de lo que compraron: sus cancelaciones superan sus ventas. Hay además 43 clientes con $F = 0$, cuya única actividad antes de octubre fueron cancelaciones.

Se conservan, por dos razones. La primera es que el propio enunciado pide incluirlos en el desempate aleatorio de 6.2. La segunda, más de fondo, es que son información legítima y no errores: un cliente con monto neto negativo es un cliente real con un comportamiento real, y además es justamente el tipo de cliente sobre el que uno querría que el análisis dijera algo. Al puntuarlos por quintiles caen automáticamente en el puntaje 1 de M, que es donde corresponde. Borrarlos hubiera sido más cómodo, pero habría escondido un 1.5 % de la base de clientes sin ninguna justificación sustantiva. Lo que sí se verificó es que son pocos: si fueran el 20 % haría falta repensar la definición de M.

¿Por qué es importante no usar nada posterior al 1 de octubre? Porque la variable que se quiere explicar, $\texttt{compra}_i$, está definida sobre la ventana del 1 de octubre al 8 de diciembre. Si R, F o M se calcularan con datos de esa ventana, el clasificador tendría dentro la respuesta y los AUC del inciso 6.3 serían ficción: la recencia medida al 8 de diciembre sería pequeña justamente para los clientes que compraron en la ventana, que es lo que se pretende predecir. Es **exactamente la misma fuga** del inciso 5.4, con otro disfraz. Allá el predictor contaminado era una media móvil centrada; aquí sería una recencia calculada demasiado tarde. La disciplina es la misma: la frontera entre lo observado y lo que se quiere predecir se fija una vez y no se cruza ni para construir variables.

6.2 Puntajes por quintiles

Se asignaron puntajes de 1 a 5 por quintiles, con 5 como el mejor en las tres dimensiones (en recencia, 5 es el más reciente, así que las etiquetas van al revés porque menos días es mejor). Para el desempate se siguió el procedimiento exacto del enunciado: todos los clientes de 6.1, incluidos los de $M \leq 0$, ordenados por `CustomerID` ascendente, barajados con `numpy.random.default_rng(2026).permutation` y puntuados con `pd.qcut(F.rank(method='first'), 5)`.

Van a tener problemas con F. ¿Por qué? Porque **F es demasiado discreta para partirse en quintiles**. Toma solo 48 valores distintos entre 3,658 clientes, y está brutalmente concentrada en los primeros: 1,444 clientes tienen $F = 1$, 693 tienen $F = 2$, 441 tienen $F = 3$. Ese primer grupo, por sí solo, es el 39 % de la base, casi dos quintiles enteros.

No existe ningún corte que parta a los clientes en cinco grupos del 20 % cada uno, porque los cortes naturales caen *dentro* de un empate masivo. El resultado se ve en los rangos efectivos de cada puntaje: los clientes con $F = 1$ terminan repartidos entre los puntajes 1, 2 y 3, y los de $F = 3$ entre los puntajes 3 y 4. La fórmula `rank(method='first')` resuelve el problema mecánico asignando rangos distintos a valores empatados según el orden en que aparezcan, que tras el barajado es un orden aleatorio.

¿Qué implica esto para dos clientes con la misma F que caen en puntajes distintos? Implica que **la diferencia entre sus puntajes no significa absolutamente nada**: es el resultado de un lanzamiento de moneda. Dos clientes con $F = 1$, idénticos en esa dimensión, pueden recibir uno un 1 y otro un 3, y si se cambiara la semilla intercambiarían lugares.

Esto tiene tres consecuencias prácticas que conviene decir en voz alta. Primero, los puntajes de F no son comparables entre clientes empatados, y cualquier decisión de negocio tomada sobre esa diferencia ("a los de puntaje 3 les mandamos cupón y a los de puntaje 1 no") sería arbitraria. Segundo, el ruido

no es neutral: *diluye* el poder predictivo de F, porque mezcla clientes idénticos en grupos distintos, y por eso conviene fijarse en que el AUC de 6.3 se calcula con los valores **crudos** y no con los puntajes. Tercero, el desempate aleatorio es preferible a las alternativas: romper los empates por `CustomerID` introduciría un sesgo sistemático (los IDs se asignan en orden de alta, así que correlacionan con la antigüedad del cliente), y al azar al menos el ruido no tiene dirección. La solución honesta sería usar menos grupos para F, o usar F cruda, pero el enunciado pide quintiles y la patología es parte de lo que hay que reportar.

6.3 *¿Qué dimensión separa mejor?*

De los 3,658 clientes, 1,845 (50.44 %) compraron entre el 1 de octubre y el 8 de diciembre.

Tabla 20: 6.3 Fracción de clientes de cada puntaje que compró entre el 1 de octubre y el 8 de diciembre. La tasa base es 50.44 %.

puntaje	R	F	M	n por quintil
1	27.3 %	31.7 %	28.6 %	732
2	37.9 %	31.9 %	38.3 %	731
3	54.4 %	44.3 %	44.3 %	732
4	65.7 %	58.7 %	60.7 %	731
5	66.9 %	85.7 %	80.3 %	732

Qué leer: F es la que más separa: va de 31.7 % a 85.7 %. R satura arriba (65.7 % y 66.9 % en los puntajes 4 y 5) pero funciona muy bien abajo: su quintil menos reciente compra con 27.3 %, el valor más bajo de la tabla. R sirve para descartar, F para seleccionar.

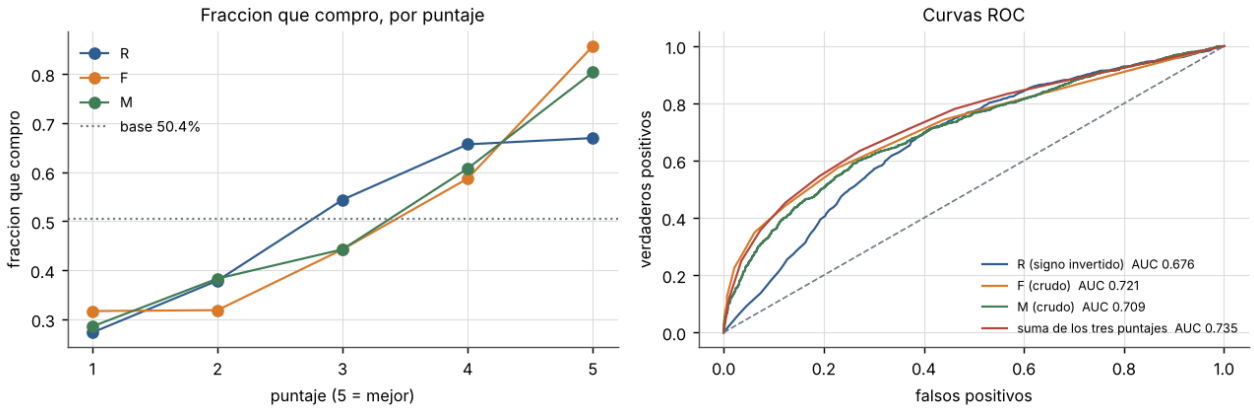


Figura 11: Izquierda: fracción de clientes que compró en la ventana, según el puntaje de cada dimensión. Derecha: curvas ROC con los valores crudos. **Qué muestra:** las tres dimensiones separan en la dirección correcta (más puntaje, más probabilidad de compra), pero F es la de pendiente más pronunciada. **Por qué importa:** la diferencia entre F y R no es sutil: el quintil top de F compra con probabilidad 85.7 % y el de R con 66.9 %.

La respuesta: F. Por las dos medidas:

- **Por separación cruda**, la diferencia entre la fracción que compra en el mejor y en el peor quintil es de 0.540 para F, 0.518 para M y 0.396 para R. F va de 31.7 % en el puntaje 1 a 85.7 % en el puntaje 5.

- **Por AUC**, F crudo da 0.721,0, M crudo 0.709,3 y R con el signo invertido 0.676,4.

Tabla 21: 6.3 AUC de cada dimensión, con los valores crudos (R con el signo invertido), y de la suma de los tres puntajes, como clasificadores de compra_i.

clasificador	AUC
R (signo invertido)	0.6764
F (crudo)	0.7210
M (crudo)	0.7093
suma de los tres puntajes	0.7352

Qué leer: la suma le gana a las tres por separado, que es la justificación empírica de usar tres números y no uno. La mejora es modesta porque las tres dimensiones están correlacionadas entre sí.

La suma de los tres puntajes gana a cualquiera por separado , con AUC 0.735,2. La mejora sobre F sola es modesta (0.014), lo cual es esperable porque las tres dimensiones están correlacionadas entre sí: un cliente que compra seguido también compró hace poco y gastó más. Pero la mejora existe, y es la justificación empírica de por qué el RFM usa tres números y no uno.

Un detalle que vale la pena notar sobre R. La curva de R es la más plana de las tres *en el extremo superior*: entre el puntaje 4 (65.7 %) y el 5 (66.9 %) casi no hay diferencia, mientras que en F el salto del 4 al 5 es de 27 puntos porcentuales. La razón es que la recencia satura: una vez que un cliente compró "hace poco", que haya sido hace tres días o hace diez no cambia mucho su probabilidad de volver. F, en cambio, sigue discriminando hasta arriba, porque un cliente con 139 facturas es cualitativamente distinto de uno con 6. Donde R sí funciona muy bien es en el extremo inferior: el quintil menos reciente compra con probabilidad 27.3 %, el más bajo de toda la tabla. R sirve para descartar, F para seleccionar.

6.4 Los campeones

Definiendo como **campeones** a los clientes con puntaje 4 o 5 en las tres dimensiones:

Tabla 22: 6.4 Los campeones: clientes con puntaje 4 o 5 en las tres dimensiones.

concepto	valor
clientes campeónes (puntaje 4 o 5 en R, F y M)	783
fracción de la base de clientes	21.41 %
venta que generaron (£)	1 302 057.01
venta total de la ventana, todos los clientes con ID (£)	2 432 839.69
fracción de la venta de la ventana	**53.52 %**

Qué leer: el 21.4 % de los clientes genera el 53.5 % de la venta del trimestre. Es casi exactamente la ley de Pareto, y es el argumento comercial entero del RFM en una línea.

Son 783 **clientes**, el 21.41 % de la base, y generaron **£**1,302,057 de los £2,432,840 de venta neta del 1 de octubre al 8 de diciembre de *todos* los clientes con `CustomerID`, incluidos los nuevos. Es decir, el 21.4 % de los clientes produce el 53.5 % de la venta.

Es casi exactamente la ley de Pareto, y es el argumento comercial entero del análisis RFM en una sola línea: con tres números por cliente, todos calculados con información disponible al 1 de octubre,

se identifica a una quinta parte de la base que vale la mitad del negocio del trimestre. Para un equipo con presupuesto limitado de retención, saber a quiénes llamar primero es casi todo el valor.

Conviene notar que el denominador es generoso con la comparación: incluye a los clientes nuevos, que por construcción no podían ser campeones. Contra el total de los clientes que sí existían al 1 de octubre la fracción sería aún mayor.

6.5 Los clientes nuevos y el límite del enfoque

Tabla 23: 6.5 Clientes sin ninguna factura de venta antes del 1 de octubre.

concepto	valor
clientes nuevos en la ventana	723
venta que generaron (£)	382 228.23
fracción de la venta de la ventana	**15.71 %**

Qué leer: casi una sexta parte de la venta del trimestre viene de gente que el 1 de octubre no existía en la base. Ningún modelo cliente por cliente puede verlos, porque no tienen fila. El pronóstico agregado de la Parte 5 sí los incluye, sin saberlo.

¿Qué fracción de la venta vino de clientes nuevos? 723 **clientes** compraron en la ventana sin tener ninguna factura de venta antes del 1 de octubre, y generaron **£**382,228, el 15.71 % de la venta neta del período con `CustomerID`. Casi una sexta parte del negocio del trimestre vino de gente que, el 1 de octubre, no existía en la base de datos.

¿Puede un análisis RFM, o cualquier modelo construido cliente por cliente, pronosticar esa venta? **No, y la imposibilidad es estructural, no un problema de ajuste.** Un modelo cliente por cliente necesita una fila por cliente para producir una predicción. Los 723 clientes nuevos *no tienen fila* el 1 de octubre: no tienen recencia (nunca compraron), no tienen frecuencia (cero facturas) ni monto. No es que el modelo los prediga mal; es que no hay nada que meterle al modelo. Ningún refinamiento del RFM, ni cambiar los quintiles, ni agregar dimensiones, ni usar un modelo más sofisticado, cambia eso. El techo de cualquier enfoque bottom-up sobre esta base es el 84.3 % de la venta.

Conéctenlo con la Parte 5 y el Proyecto 1. En el vocabulario de FPP2 §10.3–10.4, la Parte 5 es un pronóstico **top-down**: se pronostica el total agregado directamente, sin preguntar quién compra. Un modelo cliente por cliente es **bottom-up**: se pronostica cada cliente y se suman las predicciones.

¿Cuál de los dos puede ver a los clientes nuevos? El top-down, y solo el top-down. La razón es que la serie agregada *ya contiene* la venta de los clientes nuevos sin necesidad de identificarlos: cuando S2 mira la venta del 15 de noviembre, está mirando un número que incluye tanto a los clientes viejos como a los 723 nuevos, todos revueltos. El modelo no sabe quiénes son, pero tampoco le hace falta: la tasa de llegada de clientes nuevos es parte de la dinámica que la serie agregada aprende de forma implícita, igual que aprende la estacionalidad semanal.

El enfoque bottom-up tiene la ventaja contraria: dice *quién*, que es lo que se necesita para actuar (a quién llamar, a quién mandarle un cupón). Pero paga ese detalle con un sesgo sistemático hacia abajo, del tamaño exacto de la venta de los clientes nuevos, un 15.7 % en este trimestre.

La lectura para el Proyecto 1, donde se comparan ambos enfoques, es que la comparación no debería ser solo de MAE. **Se espera que el bottom-up pierda, y se sabe de antemano por cuánto**

y por qué. Lo interesante será (i) si el bottom-up pierde *más* de ese 15.7 %, lo que indicaría que además se equivoca con los clientes que sí conoce; (ii) si corregir el pronóstico bottom-up con una estimación separada de la llegada de clientes nuevos cierra la brecha; y (iii) si el detalle por cliente compensa la pérdida de precisión agregada, que es una pregunta de negocio y no de estadística. El híbrido natural (pronosticar el total con un modelo top-down y usar el RFM solo para *repartirlo* entre clientes) recoge lo mejor de ambos, y es la reconciliación que FPP2 §10.3–10.4 formaliza.

Conclusiones

1. **La prueba que uno escoge decide lo que uno ve.** El proceso semanal de la Parte 0 no tiene ninguna memoria y pasa la prueba de rezago 1 el 88.5 % de las veces, pero Ljung–Box con $m = 10$ lo rechaza el 95.5 %. Es el mismo problema de RANDU en la Tarea 2: pasar una prueba no es evidencia de ausencia de estructura.

2. **Reprobar la prueba de ruido blanco casi nunca significa "hay memoria".** En estos datos la autocorrelación venía sobre todo de una media que no era constante: el día de la semana (un índice de 1.56 el jueves contra 0.57 el domingo) y la subida navideña. La receta de quitar primero y preguntar después funcionó.

3. **La limpieza es una decisión, no un procedimiento.** Las seis reglas eliminan 7,930 filas, pero la decisión que más importa es una que *no* elimina: conservar el código `Manual`, sin el cual la venta de £38,970 del 10 de junio se queda sin su cancelación. Y el orden de las reglas cambia la bitácora aunque no cambie el resultado.

4. **El calendario es parte del modelo.** Descubrir que la tienda cierra los sábados no es un dato de color: es lo que fija $s = 6$, lo que explica por qué el pico de la ACF está en el rezago 6 y lo que hace que el promedio de los índices estacionales sea 1.20 y no 1.

5. **El diagnóstico de residuos predijo al ganador.** S2 fue el único modelo cuyos residuos pasaron Ljung–Box en 4.4, y fue el que ganó en prueba en 5.3. Lo que los dos resultados tienen en común es la diferenciación: es lo que le permite a S2 seguir un nivel que sube, y es lo que hizo que no le quedara tendencia en los residuos.

6. **Una validación solo protege contra la fuga que ocurre después de ella.** La media móvil centrada mejora el error un 10 % sin que ni la validación cruzada ni el origen móvil se den cuenta, porque la fuga viaja dentro de una columna calculada antes del corte. La única señal fue que (c) resultaba imposible de calcular.

7. **Hay un error que ninguna validación puede estimar.** El origen móvil corrigió alrededor de un 10 % del optimismo de la validación cruzada, pero siguió subestimando el error de prueba en un 39 %, porque noviembre no se parece a mayo. Con un solo año de datos esa parte no se puede medir desde adentro, y la estacionalidad anual no se puede siquiera identificar.

8. **Detrás de la serie hay clientes, pero la serie sabe algo que los clientes no.** El RFM identifica al 21.4 % de la base que genera el 53.5 % de la venta, lo cual es enormemente útil para actuar. Pero el 15.7 % de la venta del trimestre vino de clientes que no existían el 1 de octubre, y a esos solo los ve el pronóstico agregado.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.

[5] A. C. Harvey. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989. (Base de la implementación del SARIMA en `src/utils_ts.py`.)